

Формальные языки и трансляции
3 семестр
Лектор: Ахтямов П.И.
осень 2021

Авторы билетов (лучшие котики):

Спицын Николай
Савичев Дмитрий
Подзорова Полина
Чубенко Полина
Клячин Артемий
Климанова Ирина
Сбродов Егор

Содержание

1. Автоматы и регулярки	3
1. Недетерминированные конечные автоматы (НКА). Различные варианты определений. Автоматные языки.	3
2. Детерминированные конечные автоматы (ДКА). Эквивалентность ДКА и НКА. . .	6
3. Свойства класса автоматных языков. Замкнутость относительно булевых операций.	8
4. Регулярные выражения. Теорема Клини о совпадении классов регулярных и автоматных языков. Регулярный автомат, алгоритм построения.	10
5. Минимальный ДКА, его существование.	13
6. Минимальный ДКА, его единственность.	16
7. Минимальный ДКА, алгоритм построения.	17
8. Лемма о разрастании для автоматных языков. Примеры неавтоматных языков. . . .	18
9. Алгоритм проверки равенства регулярных выражений. Теорема Майхилла-Нероуда.	19
2. КС-грамматики и МП-автоматы	20
10. Иерархия Хомского. Праволинейные грамматики. Праволинейные языки. Теорема о совпадении классов автоматных и праволинейных языков.	20
11. Контекстно-свободные грамматики и языки. Примеры контекстно-свободных языков. Замкнутость и незамкнутость КС-языков относительно теоретико-множественных операций (можно пользоваться примерами не КС-языков).	23
12. Устранение бесполезных вспомогательных символов и ерс-правил для КС-грамматик.	24
13. Нормальная форма Хомского для КС-грамматик. Алгоритм приведения к нормальной форме Хомского.	25
14. Алгоритм Кока-Янгера-Касами синтаксического разбора для КС-грамматик. . . .	28
15. Лемма о разрастании для КС-языков. Примеры языков, не являющихся КС-языками.	29
16. Автоматы с магазинной памятью (МП-автоматы). Различные варианты определений. Языки, распознаваемые МП-автоматами.	30
17. Совпадение классов КС-языков и языков, распознаваемых МП-автоматами: построение автомата по грамматике.	32
18. Совпадение классов КС-языков и языков, распознаваемых МП-автоматами: построение грамматики по автомату.	34
19. Нормальная форма Грейбах для КС-грамматик. Модифицированный алгоритм Кока-Янгера-Касами для нормальной формы Грейбах: достоинства и недостатки.	36
20. Линейные и полуполулинейные множества. Лемма о том, что для всякого полуполулинейного множества есть регулярный язык. Теорема Парика: существование КС-языка для полуполулинейного множества.	38
21. Линейные и полуполулинейные множества. Теорема Парика: полуполулинейность КС-языков.	39

3. Парсеры	41
Основная информация об алгоритме Эрли	41
22. Алгоритм Эрли синтаксического разбора для КС-грамматик: доказательство корректности.	43
23. Алгоритм Эрли синтаксического разбора для КС-грамматик: доказательство полноты.	44
24. Алгоритм Эрли синтаксического разбора для КС-грамматик: обоснование сложности. Примеры случаев, где Эрли ведёт себя квадратично. Как реализовать алгоритм Эрли, чтобы он был эффективным	45
25. Анализатор перенос-свёртка, недостатки анализатора.	49
26. Определение LR-грамматики, примеры LR и не LR-грамматик. Стековая аналогия определения (нет конфликтов). Вопрос на отл: однозначность lg грамматики. . .	50
27. Алгоритм построения LR-таблицы. Вопрос на отл: доказательство корректности и полноты. Если верно определение, таблица строится и если не верно, не строится. Критерий LR-овости (отсутствие противоречий).	53
28. Алгоритм разбора по LR-таблице. Структура стека. Корректность и полнота разбора (на отл).	55
4. Конечные преобразователи	56
29. Конечные преобразователи и задаваемые ими преобразования. Различные варианты определения. Примеры конечных преобразований. Теорема Нива.	56
30. Замкнутость конечных преобразований относительно композиции.	59
31. Замкнутость класса автоматных языков относительно конечных преобразований. .	62
32. Замкнутость класса контекстно-свободных языков относительно конечных преобразований.	63
33. Лемма о разрастании для конечных преобразований. Примеры соответствий, не задаваемых конечными преобразованиями.	65

1. Автоматы и регулярки

1. Недетерминированные конечные автоматы (НКА). Различные варианты определений. Автоматные языки.

Определение: Алфавит Σ — непустое конечное множество, элементы которого называются символами. При этом Σ^* — множество слов, состоящее из всех слов Σ , $\varepsilon \in \Sigma^*$.

Определение: Формальный язык L — некоторое подмножество Σ^* .


Определение: Недетерминированный конечный автомат (НКА) — кортеж $M = \langle Q, \Sigma, \Delta, q_0, F \rangle$:

1. Q — множество состояний, Q — конечное множество, то есть $|Q| < \infty$;
2. Σ — алфавит;
3. $\Delta \subset Q \times \Sigma^* \times Q$ — множество переходов (т.е. $\text{состояние}_1 \xrightarrow{\text{слово}} \text{состояние}_2$);
4. $q_0 \in Q$ — стартовое состояние;
5. $F \subset Q$ — множество завершающих состояний.

Определение: Конфигурация в автомате $\langle Q, \Sigma, \Delta, q_0, F \rangle$ — элемент $\langle q, w \rangle \in Q \times \Sigma^*$.

Определение: Отношение \vdash достижимости по M — наименьшее рефлексивное транзитивное отношение над $Q \times \Sigma^*$, такое что:

1. $\forall w \in \Sigma^* : (\langle q_1, w \rangle \rightarrow q_2) \in \Delta \implies \langle q_1, w \rangle \vdash \langle q_2, \varepsilon \rangle$
2. $\forall u, v \in \Sigma^* : \langle q_1, u \rangle \vdash \langle q_2, \varepsilon \rangle, \langle q_2, v \rangle \vdash \langle q_3, \varepsilon \rangle \implies \langle q_1, uv \rangle \vdash \langle q_3, \varepsilon \rangle$
3. $\forall u \in \Sigma^* : \langle q_1, u \rangle \vdash \langle q_2, \varepsilon \rangle \implies \forall v \in \Sigma^* \langle q_1, uv \rangle \vdash \langle q_2, v \rangle$



$$M = \langle Q, \Sigma, \Delta, q_0, F \rangle$$

Пример: Рассмотрим как автомат с картинки распознает слово $abab$:

$$\langle q_0, abab \rangle \vdash \langle q_0, bab \rangle \vdash \langle q_1, ab \rangle \vdash \langle q_1, \varepsilon \rangle$$

По транзитивности получаем: $\langle q_0, abab \rangle \vdash \langle q_1, \varepsilon \rangle$

Поясним переходы:

Первый и второй \vdash работают по свойству 3, а третий \vdash работает по свойству 1.

Определение: Для автомата $M = \langle Q, \Sigma, \Delta, q_0, F \rangle$ языком $L(M)$, задаваемым автоматом M , является множество $\{w \in \Sigma^* \mid \exists q \in F : \langle q_0, w \rangle \vdash \langle q, \varepsilon \rangle\}$.

Определение: Язык L — автоматный, если существует такой НКА M , что $L = L(M)$.


Утверждение об НКА с одним завершающим состоянием: Для любого автоматного языка L существует НКА $M' = \langle Q', \Sigma, \Delta', q'_0, F' \rangle$, такой что $L(M') = L$, и $|F'| = 1$.

Идея доказательства: добавим одно завершающее состояние q_f на замену остальным и добавим ε -переходы из "предыдущих" завершающих состояний в новое.

Введем обозначения: \vdash_i - достижимость за i переходов


▲ L — автоматный язык, значит, существует НКА $M = \langle Q, \Sigma, \Delta, q_0, F \rangle$, такой что $L(M) = L$. Введём $M' = \langle Q \cup \{q_f\}, \Sigma, \Delta', q_0, \{q_f\} \rangle$, где $\Delta' = \Delta \cup \{ \langle q, \varepsilon \rangle \mapsto q_f \mid q \in F \}$. Далее нужно доказать, что $L(M) = L(M')$.

Докажем, что $L(M) \subset L(M')$. По определению из того, что $w \in L(M)$, следует, что существует состояние $q \in F$, что $\langle q_0, w \rangle \vdash \langle q, \varepsilon \rangle$. В автомате M' есть переход $\langle q, \varepsilon \rangle \mapsto q_f \implies \langle q, \varepsilon \rangle \vdash \langle q_f, \varepsilon \rangle$. Так как $\langle q_0, w \rangle \vdash \langle q, \varepsilon \rangle \vdash \langle q_f, \varepsilon \rangle$, то $w \in L(M')$.



Докажем, что $L(M) \supset L(M')$. Из того, что $w \in L(M')$, следует, что $\langle q_0, w \rangle \vdash \langle q_f, \varepsilon \rangle$. Но так как в q_f можно добраться только по ε -переходу, то существует состояние q' , что $\langle q_0, w \rangle \vdash \langle q', \varepsilon \rangle \vdash_1 \langle q_f, \varepsilon \rangle \implies q' \in F$. А в автомате M $\langle q_0, w \rangle \vdash \langle q', \varepsilon \rangle$. Значит, $w \in L(M)$. ■

Утверждение об НКА с не более однобуквенными переходами: Для любого автоматного языка L существует НКА $M = \langle Q, \Sigma, \Delta, q_0, F \rangle$, такой что $L = L(M)$ и $\forall (\langle q_1, w \rangle \mapsto q_2) \in \Delta \mid |w| \leq 1$



Теорема об НКА с однобуквенными переходами: Для любого НКА $M = \langle Q, \Sigma, \Delta, q_0, F \rangle$ существует НКА $M' = \langle Q, \Sigma, \Delta', q_0, F' \rangle$, такой что $L(M) = L(M')$ и:

$$\forall (\langle q_1, w \rangle \rightarrow q_2) \in \Delta \mid |w| = 1$$

▲ Обозначим множество вершин, достижимых из q по w как $\Delta(q, w) = \{q' \mid \langle q, w \rangle \vdash \langle q', \varepsilon \rangle\}$. Считаем, что в любом переходе $|w| \leq 1$. Введём следующие множества:

$$F' := \{q \mid \Delta(q, \varepsilon) \cap F \neq \emptyset\}$$

$$\Delta' = \{ \langle q_1, a \rangle \rightarrow q_2 \mid \exists q_3 \in \Delta(q_1, \varepsilon) : \langle q_3, a \rangle \rightarrow q_2 \}$$

Докажем, что $L(M') = L(M)$

Пусть $w \in L(M')$. Тогда $\exists q' \in F' : \langle q_0, w \rangle \vdash_{M'} \langle q', \varepsilon \rangle$.

Тогда $\exists q \in F : \Delta(q', \varepsilon) = q \implies \langle q', \varepsilon \rangle \vdash_M \langle q, \varepsilon \rangle$.

Рассмотрим $w = w_1 w_2 \dots w_n$. Тогда верно следующее:

$$\forall m \exists q'_m : \langle q'_{m-1}, w_m \rangle \rightarrow q'_m \in \Delta' \quad (q'_m := q') \quad (1)$$

$$\text{Значит, } \exists q_m : \Delta(q'_{m-1}, \varepsilon) = q_m, \langle q_m, w_m \rangle \rightarrow q'_m \text{ и } \langle q'_{m-1}, w_m \rangle \vdash_M \langle q'_m, \varepsilon \rangle \quad (2)$$

Из (1) и (2) следует, что

$$\langle q'_0, w_1 \dots w_m \rangle \vdash_M \langle q'_1, w_2 \dots w_m \rangle \vdash_M \langle q'_2, w_3 \dots w_m \rangle \dots \vdash_M \langle q'_m, w_m \rangle \vdash_M \langle q, \varepsilon \rangle$$

Следовательно, $w \in L(M)$.

В обратную сторону: $w \in L(M) \Rightarrow \exists q \in F : \langle q_0, w \rangle \vdash_M \langle q, \varepsilon \rangle$. Пусть $w = w_1 w_2$ (для больших n аналогично). Тогда есть цепь

- $\langle q_0, w_1 w_2 \rangle \vdash_M \langle q'_1, w_1 w_2 \rangle$
- $\langle q'_1, w_1 w_2 \rangle \vdash_{M,1} \langle q_1, w_2 \rangle$ (читаем символ w_1)
- $\langle q_1, w_2 \rangle \vdash_M \langle q'_2, w_2 \rangle$
- $\langle q'_2, w_2 \rangle \vdash_{M,1} \langle q_2, \varepsilon \rangle$ (читаем символ w_2)
- $\langle q_2, \varepsilon \rangle \vdash_M \langle q, \varepsilon \rangle$

Получаем, что $\Delta(q_0, \varepsilon) = q'_1, \langle q'_1, w_1 \rangle \rightarrow q_1 \Rightarrow \langle q_0, w_1 \rangle \rightarrow q_1 \in \Delta'$.

Аналогично $\langle q_1, w_2 \rangle \rightarrow q_2 \in \Delta'$. Так как $\Delta(q_2, \varepsilon) = q \in F \Rightarrow q_2 \in F'$.

Тогда $\langle q_0, w_1 w_2 \rangle \vdash_{M'} \langle q_1, w_2 \rangle \vdash_{M'} \langle q_2, \varepsilon \rangle$ и $w = w_1 w_2 \in L(M')$ ■

2. Детерминированные конечные автоматы (ДКА). Эквивалентность ДКА и НКА.

Определение: НКА $M = \langle Q, \Sigma, \Delta, q_0, F \rangle$ называется детерминированным (ДКА), если выполнено:

1. $\forall (\langle q_1, w \rangle \rightarrow q_2) \in \Delta' : |w| = 1$
(все переходы являются однобуквенными);
2. $\forall a \in \Sigma, q \in Q \mid \Delta(q, a) \mid \leq 1$
(из одного состояния по одному символу можно перейти не более, чем в одно состояние);

Теорема о эквивалентности ДКА и НКА Для любого НКА $M = \langle Q, \Sigma, \Delta, q_0, F \rangle$ существует ДКА M' , такой что $L(M) = L(M')$.

▲ Обозначим $\Delta(S, w) = \bigcup_{q \in S} \Delta(q, w)$, где $w \in \Sigma^*$, $S \subset Q$. Построим ДКА $M' = \langle 2^Q, \Sigma, \Delta', \{q_0\}, F' \rangle$, где:

1. $F' = \{S \subset Q \mid S \cap F \neq \emptyset\}$;
2. $\Delta' = \{\langle S, a \rangle \rightarrow \Delta(S, a)\}$.

Чтобы понять, что из себя представляет новое множество переходов Δ' , докажем следующую лемму:

Лемма: $\Delta'(\{q_0\}, w) = \Delta(\{q_0\}, w)$, где слева – вершина в M' , а справа – подмножество в M .

Докажем лемму индукцией по длине слова w .

База. $w = \varepsilon$, тогда $\Delta(\{q_0\}, \varepsilon) = \{q_0\} = \Delta'(\{q_0\}, \varepsilon)$, так как все переходы в автомате M' являются однобуквенными.

Переход. $w = ua$, где $a \in \Sigma$, $u \in \Sigma^*$.

Сначала покажем, что $\Delta(\{q_0\}, ua) = \Delta(\Delta(\{q_0\}, u), a)$:

$$\Delta(\{q_0\}, ua) = \{q \mid \langle q_0, ua \rangle \vdash \langle q, \varepsilon \rangle\} \text{ из определения } \Delta$$

По однобуквенности переходов и транзитивности:

$$\begin{aligned} \{q \mid \langle q_0, ua \rangle \vdash \langle q, \varepsilon \rangle\} &= \{q \mid \exists q' : \langle q_0, ua \rangle \vdash \langle q', a \rangle \vdash \langle q, \varepsilon \rangle\} = \{q \mid \exists q' \in \Delta(\{q_0\}, u) : \langle q', a \rangle \vdash \\ &\quad \langle q, \varepsilon \rangle\} = \Delta(\Delta(\{q_0\}, u), a) \end{aligned}$$

По предположению индукции:

$$\Delta(\Delta(\{q_0\}, u), a) = \Delta(\Delta'(\{q_0\}, u), a)$$

$$S := \Delta'(\{q_0\}, u)$$

$$\Delta(S, a) = \Delta'(S, a) \text{ (следует из определения переходов в ДКА)}$$

$$\Delta'(\Delta'(\{q_0\}, u), a) = \Delta'(\{q_0\}, ua)$$

Лемма доказана.

Теперь покажем, что $w \in L(M) \iff w \in L(M')$.

$$\begin{aligned} w \in L(M) &\iff \exists q \in F : \langle q_0, w \rangle \vdash \langle q, \varepsilon \rangle \iff \Delta(q_0, w) \cap F \neq \emptyset \iff \Delta(\{q_0\}, w) \cap F \neq \emptyset \stackrel{lemma}{\iff} \\ &\Delta'(\{q_0\}, w) \cap F \neq \emptyset \\ T &:= \Delta'(\{q_0\}, w) \\ T \cap F \neq \emptyset &\iff T \in F', \Delta'(q'_0, w) \in F', q'_0 = \{q_0\} \\ T \in F' &\iff w \in L(M') \quad \blacksquare \end{aligned}$$

3. Свойства класса автоматных языков. Замкнутость относительно булевых операций.


Определение: Полный ДКА. Полный ДКА (ПДКА) - ДКА, для которого выполнено:

$$\forall a \in \Sigma, q \in Q \quad |\Delta(q, a)| = 1$$

Утверждение: Для любого автоматного языка L существует ПДКА M , такой что $L(M) = L$ (т.е. автоматы распознают одинаковое множество слов);

Метод построения ПДКА из ДКА:

- 1) строим "стоковую" вершину.
- 2) Добавляем из всех вершин переходы по недостающим буквам в "сток".



Появятся ли новые слова? - нет, потому что, если мы попали в стоковую вершину, то не сможем "выбраться" из неё.

Определение: Итерация Клини для языка L .

$$L^* = \bigcup_{k=0}^{\infty} L^k$$


Теорема: Класс автоматных языков замкнут относительно

1. Конкатенации
2. Объединения
3. Пересечения
4. Итерации Клини
5. Дополнения

▲ Далее будем рассматривать только НКА с одним завершающим состоянием. Для того чтобы после операции у итогового автомата было одно завершающее состояние, добавляем состояние и соединяем завершающие состояния с ним с помощью ε -переходов. (делаем новое состояние - завершающим, а старые - не завершающими)


- 1) Конкатенация M_1 и M_2 :

Соединяем ε -переходами завершающее состояние M_1 со стартовыми состояниями M_2 .




2) Объединение M_1 и M_2 :

Добавляем стартовое состояние. Соединяем её со стартовыми состояниями M_1 и M_2 с помощью ε -переходов.




4) Итерации Клини над M_1 :

Добавляем стартово-завершающее состояние. С помощью ε -переходов соединяем её с начальными состояниями M_1 , а завершающее состояния M_1 с ней.



3) Пересечение M_1 , M_2 :

Строим "декартово произведение" автоматов с одно буквенными переходами.



То есть пересечение будет состоять из состояний, каждому из которых соответствует пара чисел (i, j) , это номера состояний из M_1 и M_2 соответственно, которым это состояние соответствует. И между состояниями (i_1, j_1) и (i_2, j_2) будет проходить ребро с символом k , если между i_1 и i_2 проходило ребро с символом k в M_1 и между j_1 и j_2 проходило ребро с символом k в M_2 . (i, j) - стартовое состояние, если i - стартовое в M_1 , j - стартовое в M_2 . Аналогично с завершающим состоянием.

5) Дополнение: строим ПДКА и инвертируем терминальность всех состояний.

4. Регулярные выражения. Теорема Клини о совпадении классов регулярных и автоматных языков. Регулярный автомат, алгоритм построения.

Введем обозначения:

Regex (регулярное выражение) обозначим за R ,

Language (язык) – за L ,

$L(R_i)$ (язык, который задается регулярным выражением R) – L_i .

Определение: Рекурсивное определение регулярного выражения.

$Regex(R)$	$Language(L_i = L(R_i))$
0	\emptyset
1	$\{\varepsilon\}$
$a, a \in \Sigma$	$\{a\}$
$R_1 + R_2$	$L_1 \cup L_2$
$R_1 \cdot R_2$	$L_1 \cdot L_2$
R^*	L^*

Здесь ε – пустое слово, « \cdot » – операция конкатенации языков (в полученном языке $L_1 \cdot L_2$ лежат слова вида $a_1 a_2$, где слово a_1 лежит в языке L_1 , а слово a_2 лежит в языке L_2), « $*$ » – звезда Клини.

Напомним определение звезды Клини: $V^* = \bigcup_{i=0}^{\infty} V^i$

Приоритет операций в регулярных выражениях (левее – приоритетнее): $*$ \rightarrow \cdot \rightarrow $+$

Определение: Язык L – регулярный, если он задается регулярным выражением.


Теорема Клини: Классы регулярных и автоматных языков совпадают.

▲ Докажем два вложения:

1. Регулярные \subseteq Автоматные

Индукция по построению выражения. Немного изменим утверждение – докажем, что по регулярному выражению можно построить НКА с 1 завершающим состоянием, который задает тот же язык.

База: Построим автоматы для регулярных выражений: $0, 1, a \in \Sigma$.



Переход:

1) $R = R_1 + R_2$. Построим автомат A_1 для R_1 , для которого вершина S_1 – стартовая, а вершина F_1 – единственная терминальная. Для R_2 это будет автомат A_2 со стартовой вершиной S_2 и терминальной F_2 . Создадим новую вершину S , которая и будет стартовой в новом автомате. Из нее проведем два ребра с ε -переходами в S_1 и в S_2 . Аналогично соединим завершающие в автоматах с новой завершающей вершиной F . Нетрудно доказать, что такой автомат задаст тот же язык, что и наше регулярное выражение.

2) $R = R_1 \cdot R_2$. Аналогично прошлому пункту получим автоматы для R_1 и R_2 с теми же обозначениями. Вершина S_1 будет стартовой в нашем новом автомате. Добавим также ε -переход из F_1 в S_2 , уберем терминальность F_1 .

3) $R = R_1^*$. Построим автомат A_1 для R_1 со стартовой вершиной S_1 и терминальной вершиной F_1 . Создадим вершину S – новую стартовую вершину, пометим ее терминальной. Добавим из нее и из F_1 ε -переход в S_1 .

2. Автоматные \subseteq Регулярные


Замечание: Регулярный автомат – НКА, в котором на ребрах записаны регулярные выражения. Докажем утверждение для регулярных автоматов.

Замечание: Всякий НКА задается регулярным автоматом с 1 завершающим состоянием.


Индукция по $|Q|$ (количеству состояний – вершин) в регулярном автомате.

База:

1) $|Q| = 1$. Тогда в регулярном автомате стартовое состояние является завершающим, и можно однозначно построить регулярное выражение. Такому автомату соответствует регулярное выражение a^*




2) $|Q| = 2$. Стартовое состояние и завершающее состояние различны, и можно тоже однозначно построить регулярное выражение. Такому автомату соответствует регулярное выражение $\alpha^* \beta (\gamma + \delta \alpha^* \beta)^*$




Для случая, когда завершающее состояние – это начальная вершина, регулярное выражение будет $(\gamma + \delta \alpha^* \beta)^*$.


Переход: **Замечание:** Есть нестартовая и незавершающая вершина!



Кратные ребра означают, что мы можем выбрать, какой символ будем использовать. Именно этот смысл и несет в себе операция «+».



3) Удаляем нестартовое и незавершающее состояние:



Теперь у нас на одно состояние стало меньше, т.е. мы можем воспользоваться утверждением индукции. ■

5. Минимальный ДКА, его существование.

Мотивировка: может быть много состояний. А еще не очень понятно, как сравнивать два автомата на эквивалентность. Вернее, если проверять «в лоб», будет долго. Один из способов решить эти проблемы – минимизация автомата.

Пусть $L \subset \Sigma^*$ – автоматный язык, M – ПДКА для L .

Определение: Минимальный ПДКА M , распознающий язык L , если M – минимальный по количеству состояний.

Определение: Определим отношение эквивалентности \sim_L на Σ^* :

$$u \sim_L v \iff \forall w \in \Sigma^* (uw \in L \iff vw \in L)$$

Определение корректно (рефлексивность, симметричность и транзитивность очевидны).

Множество классов эквивалентности в этом случае: $\Sigma^*/\sim_L := \{\{u \mid u \sim_L v\} \mid v \in \Sigma^*\}$

Определение: Определим отношение эквивалентности \sim_M на Q :

$$q_1 \sim_M q_2 \iff \forall w \in \Sigma^* (\Delta(q_1, w) \in F \iff \Delta(q_2, w) \in F)$$

Если $q_1 \sim_M q_2$, то состояния можно объединить.

Напоминание: Множество вершин, достижимых из q по w – $\Delta(q, w) = \{q' \mid \langle q, w \rangle \vdash \langle q', \varepsilon \rangle\}$.

Лемма Пусть $L_q := \{w \mid \Delta(q_0, w) = q\}$. Тогда каждый класс эквивалентности в нашем фактор-множестве является объединением классов в L_q .

▲ Возьмем слово $u \in [u] \in \Sigma^*/\sim_L$, где $[u]$ – это класс эквивалентности для u . Рассмотрим путь по u из q_0 , а именно, $q_u = \Delta(q_0, u)$. Для любого слова $w \in [u]$, $q_w = \Delta(q_0, w)$. Тогда $[u] = \bigcup_{q_w, w \in [u]} L_{q_w}$. Далее докажем, почему это так.

Пусть $v \in [u] \implies v \sim_L u \implies q_v = \Delta(q_0, v) \implies v \in L_{q_v}$. Тогда $v \in \bigcup_{q_w, w \in [u]} L_{q_w}$.

Пусть $v \in \bigcup_{q_w, w \in [u]} L_{q_w}$. Тогда существует состояние $q_z, z \in [u]$, что $v \in L_{q_z} = \{w \mid \Delta(q_0, w) = q_z\}$.

$$z \in [u] \implies z \sim_L u \stackrel{def}{\implies} \forall w \in \Sigma^* (zw \in L \iff uw \in L)$$

$$v \in L_{q_z} \implies \left. \begin{array}{l} \Delta(q_0, v) = q_z \\ \Delta(q_0, z) = q_z \end{array} \right\} \implies v \sim_L z \text{ так как } \forall w \in \Sigma^* \Delta(q_0, vw) \stackrel{(*)}{=} \Delta(q_0, zw)$$

$$(*): \Delta(q_0, vw) = \Delta(\Delta(q_0, v), w) = \Delta(q_z, w) = \Delta(\Delta(q_0, z), w) = \Delta(q_0, zw)$$

Так как $v \sim_L z, z \in [u]$, то $v \in [u]$. Значит, $[u] = \bigcup_{q_w, w \in [u]} L_{q_w}$, и каждый класс эквивалентности из Σ^*/\sim_L – объединение классов в L_q . ■

Следствие $|\Sigma^*/\sim_L| \leq |Q|$

Теперь перейдем к минимальному ПДКА, а именно докажем его существование (тут) и единственность с точностью до изоморфизма (билет 6).

Лемма Для любого автоматного языка L существует ПДКА M' такой, что все состояния в M' попарно неэквивалентны.

Что необходимо доказать?

- 1) Переходы и завершающие состояния согласованы
- 2) Распознаваемые языки совпадают
- 3) Состояния попарно неэквивалентны

▲ Рассмотрим автомат над классами эквивалентности \sim_M . Класс эквивалентности q обозначим за $[q]$. $M' = \langle Q/\sim_M, \Sigma, \Delta', [q_0], F' \rangle$, где:

$$\begin{aligned}\Delta' &= \{ \langle [q_1], a \rangle \rightarrow [q_2] \mid \exists \langle q_1, a \rangle \rightarrow q_2 \in \Delta \} \\ F' &= \{ [q_f] \mid q_f \in F \}\end{aligned}$$

- 1) Проверим, что множества Δ', F' заданы корректно.

Для Δ' : Пусть $q_1 \sim_m q'_1$, и существует a такое, что $\Delta(q_1, a) \approx_m \Delta(q'_1, a)$.

$$\begin{aligned}q_1 \sim_M q'_1 &\stackrel{def}{\implies} (\forall w \in \Sigma^* \quad \Delta(q, w) \in F \iff \Delta(q'_1, w) \in F) \\ w = au &\implies (\forall u \in \Sigma^* \quad \Delta(q_1, au) \in F \iff \Delta(q'_1, au) \in F)\end{aligned}$$

Далее обозначим $\Delta(q_1, a) = q_2$, а $\Delta(q'_1, a) = q'_2$.

$$\begin{aligned}\Delta(q_1, au) &= \Delta(\Delta(q_1, a), u) = \Delta(q_2, u) \\ \Delta(q'_1, au) &= \Delta(q'_2, u) \\ (\Delta(q_2, u) \in F \iff \Delta(q'_2, u) \in F) &\implies q_2 \sim_m q'_2.\end{aligned}$$

Приходим к противоречию.

Для F' :

$$\begin{aligned}q_1 \in F, q_2 \sim_M q_1 &\stackrel{w=\varepsilon}{\implies} (\Delta(q_1, \varepsilon) \in F \iff \Delta(q_2, \varepsilon) \in F) \\ \text{Значит, } q_1 \in F &\iff q_2 \in F\end{aligned}$$

- 2) Теперь покажем, что $L(M) = L(M')$.

Для этого нужно показать, что $w \in L(M) \iff \Delta(q_0, w) \in F \stackrel{?}{\iff} \Delta([q_0], w) \in F'$.

Докажем утверждение: $\forall u : \Delta(q_0, u) = q_1 \iff \Delta([q_0], u) = [q_1]$.

Индукция по длине слова u .

База. $|u| = 0 \implies u = \varepsilon$. Тогда $\Delta(q_0, \varepsilon) = q_0$, $\Delta([q_0], \varepsilon) = [q_0]$.

Переход. Пусть $u = va$, $v \in \Sigma^*$, $a \in \Sigma$.

$$\Delta(q_0, va) = q_1 \implies \exists q_2 \Delta(q_0, v) = q_2, \Delta(q_2, a) = q_1$$

По предположению индукции, $\Delta([q_0], u) = [q_2]$, $\Delta([q_2], a) = [q_1]$, так как переход $\langle q_2, a \rangle \rightarrow q_1 \in \Delta$ тогда и только тогда, когда $\langle [q_2], a \rangle \rightarrow [q_1] \in \Delta'$. По транзитивности, $\Delta([q_0], ua) = [q_1]$.

3) Теперь покажем, что состояния попарно неэквивалентны. В автомате, построенном на классах эквивалентности состояний никакие два состояния не эквивалентны, потому что тогда бы они лежали в одном классе, т.е. были бы одним состоянием.

Пусть $[q_1] \sim_{M'} [q_2]$. Тогда $\forall w : \Delta_{M'}([q_1], w) \in F' \iff \Delta_{M'}([q_2], w) \in F'$ по определению.

$$[q_{1f}] = \Delta_{M'}([q_1], w) \in F'$$

$$[q_{2f}] = \Delta_{M'}([q_2], w) \in F'$$

$$\exists q_{1f} \in F : \Delta_M(q_1, w) = q_{1f} \in F \iff \exists q_{2f} \in F : \Delta_M(q_2, w) = q_{2f} \in F$$

$$q_1 \sim_M q_2 \implies [q_1] = [q_2]$$

■

Теорема: M — минимальный ПДКА, распознающий язык L , тогда и только тогда, когда любые два состояния попарно неэквивалентны и все состояния достижимы из стартового.

Теперь запишем более формально:

$$M \text{ — минимальный ПДКА} \iff \begin{cases} \forall q_1, q_2 \in Q \quad q_1 \approx q_2 \\ \forall q \in Q \quad \exists w \in \Sigma^* : \langle q_0, w \rangle \vdash \langle q, \varepsilon \rangle \end{cases}$$

▲

\implies Если $q_1 \sim_M q_2$, то $[q_1] = [q_2]$, и их можно объединить в одно состояние, значит, M не был бы минимальным, и тогда из минимальности следует, что $q_1 \approx_M q_2$. Если среди состояний есть недостижимые, то если их удалить, то множество принимаемых слов не изменится.

\Leftarrow По следствию из леммы о L_q : $|\Sigma^*/\sim_L| \leq |Q|$. Рассмотрим w_1, w_2 такие, что $\Delta(q_0, w_1) \neq \Delta(q_0, w_2)$. Введём обозначения:

$$\Delta(q_0, w_1) = q_1$$

$$\Delta(q_0, w_2) = q_2$$

Неэквивалентность состояний q_1, q_2 означает, что существует слово w , что б.о.о:

$$\Delta(q_1, w) = \Delta(q_0, w_1 w) \in F \iff w_1 w \in L$$

$$\Delta(q_2, w) = \Delta(q_0, w_2 w) \notin F \iff w_2 w \notin L$$

Следовательно, получили что $w_1 \not\approx_L w_2$

Тогда для автомата M со множеством состояний Q' выполняется, что $|\Sigma^*/\sim_L| \geq |Q'|$, но тогда $|Q| \geq |\Sigma^*/\sim_L| \geq |Q'|$, и M — минимальный. ■

6. Минимальный ДКА, его единственность.

Определение: M — минимальный ПДКА, распознающий язык L , если M минимальный по количеству состояний.

В предыдущем билете мы доказали существование минимального ПДКА (это логически следует из леммы и теоремы).

Замечание 1: в МПДКА $M = \langle Q, \dots \rangle \hookrightarrow |\Sigma^*/\sim_L| = |Q|$

Замечание 2: $[u] \in \Sigma^*/\sim_L \implies [u] = \cup_q L_q$, где $L_q := \{w \mid \Delta(q_0, w) = q\}$ в МПДКА. Тогда получаем, что $[u] \in \Sigma^*/\sim_L \implies \exists! q : [u] = L_q$.

Теорема: Для любого автоматного языка L существует единственный с точностью до изоморфизма минимальный ПДКА M , такой что $L = L(M)$.

▲ Пусть M — минимальный ПДКА, Q_M — множество его состояний.

Построим автомат $M_0 = \langle \Sigma^*/\sim_L, \Sigma, \Delta, [\varepsilon], \{[w] \mid w \in L\} \rangle$. Для любых $u \in \Sigma^*$, $a \in \Sigma$ верно, что $\Delta([u], a) = [ua]$ (факт 1). Так как количество состояний автомата, соответствующему языку L , конечно, то по следствию из леммы о классах эквивалентности и L_q : $|\Sigma^*/\sim_L| < \infty$.

Факт 1 верен вследствие следующего:

$$\begin{aligned} u \sim_L v &\implies ua \sim_L va \iff \forall w (uaw \in L \iff vaw \in L) \\ w' = aw, \forall w' (uw' \in L &\iff vw' \in L) \iff u \sim_L v \end{aligned}$$

Так как $u \sim_L v$, то если $u \in L$, то $v \in L$, и наоборот (просто берем $w = \varepsilon$).

Теперь рассмотрим $\psi : Q_M \rightarrow \Sigma^*/\sim_L$, $\psi(q) = \{w \mid \Delta(q_0, w) = q\} = L_q$. Из замечаний $\implies \psi$ — взаимнооднозначное отображение. Более того, покажем, что ψ — изоморфизм между автоматами, как графами. Для этого нужно показать, что:

1. $\Delta(\psi(q), a) = [\psi(q) a]$;
2. $q \in F \iff \psi(q) \subseteq L$.

Покажем, почему выполняется (1).

$$\begin{aligned} \psi(q) &= [u], \psi(q') = [u'], \Delta(q, a) = q' \\ \Delta(\psi(q), a) &= \Delta(\{w \mid \Delta(q_0, w) = q\}, a) = \{w' = wa \mid \langle q_0, w' \rangle = q'\} = [wa] \\ [u] &= [w], [u'] = [wa] \text{ по транзитивности переходов в автомате} \end{aligned}$$

Покажем, почему выполняется (2). Из того, что $q \in F$, следует, что слова из множества $\psi(q) = \{w \mid \Delta(q_0, w) = q\}$ принадлежат языку L , так они распознаются автоматом, поскольку q является завершающим состоянием. А так как $\psi(q) = \{w \mid \Delta(q_0, w) = q\} \subseteq L$, то так как они распознаются автоматом, соответствующему языку L , то $q \in F$.

Пусть ψ_1 — изоморфизм между минимальными ПДКА M_1 и M_0 , ψ_2 — изоморфизм между минимальными ПДКА M_2 и M_0 . Тогда M_1 и M_2 изоморфны между собой — этому соответствует изоморфизм $\psi_2^{-1} \circ \psi_1$, композиция изоморфизмов является изоморфизмом. ■

7. Минимальный ДКА, алгоритм построения.

Мы хотим преобразовать автомат так, чтобы его состояния были попарно неэквивалентны. Но у нас есть только слова. Как быть? Введем эквивалентность по словам фиксированной длины.

Определение: $q_1 \underset{n}{\sim} q_2$, если для любого слова $w : |w| \leq n$:

$$\Delta(q_1, w) \in F \iff \Delta(q_2, w) \in F$$

. Это отношение эквивалентности (аналогично своему M -аналогу), поэтому можно ввести $Q/\underset{n}{\sim}$.

Лемма: $q_1 \underset{|Q|-2}{\sim} q_2 \implies q_1 \sim q_2$

▲ Если $q_1 \underset{i+1}{\sim} q_2 \implies q_1 \underset{i}{\sim} q_2$, тогда $|Q/\underset{i}{\sim}| \leq |Q/\underset{i+1}{\sim}|$.

Покажем, что если $|Q/\underset{i}{\sim}| = |Q/\underset{i+1}{\sim}|$, то $|Q/\underset{i+1}{\sim}| = |Q/\underset{i+2}{\sim}|$. Пусть существуют состояния q_1 и q_2 . такие что $q_1 \underset{i+2}{\sim} q_2$, $q_1 \underset{i+1}{\sim} q_2$.

Тогда $\exists u, |u| \leq i+2$, что без ограничения общности $\Delta(q_1, u) \in F$, $\Delta(q_2, u) \notin F$. Заметим, что должно быть верно, что $|u| = i+2$, иначе возникнет противоречие с $(i+1)$ -эквивалентностью. Тогда пусть $u = av$, где a – некоторый символ.

Рассмотрим $p_1 = \Delta(q_1, a), p_2 = \Delta(q_2, a) \implies \Delta(p_1, v) \in F, \Delta(p_2, v) \notin F$, при этом $|v| \leq i+1$

Тогда $p_1 \underset{i+1}{\sim} p_2$ так как существует слово длины $i+1$, которое их различает $\implies p_1 \underset{i}{\sim} p_2 \implies q_1 \underset{i+1}{\sim} q_2$ Противоречие.

Отсюда следует, что если $|Q/\underset{i}{\sim}| = |Q/\underset{i+1}{\sim}|$, то $|Q/\underset{i+1}{\sim}| = |Q/\underset{i+2}{\sim}|$. И так для всех i . Поэтому если мы остановились, новые классы эквивалентности не появятся. Понятно, что мы можем увеличить класс эквивалентности $O(|Q|)$ раз

■

Поэтому наш алгоритм выглядит так:

Множество $Q/\underset{0}{\sim}$ представляет собой $\{F, Q \setminus F\}$, то есть это множество из множества завершающих состояний и множества состояний, не являющихся завершающими.

До тех пор, пока количество классов эквивалентности меняется, увеличиваем длину слов, по которым проверяем эквивалентность.

Пусть у нас была длина n , мы перешли к $n+1$. Рассмотрим какой-то класс эквивалентности.

Посмотрим на переход по первой букве. Заметим тогда, что нам останется пройти n символов. Все эти вершины (на расстоянии 1) мы уже распределили по классам эквивалентности на основе слов длины n , поэтому нужно для каждого состояния найти множество классов эквивалентности его соседей. Если множества различаются, то эти состояния теперь разойдутся по разным классам. Совпадают, значит, останутся в одном классе.

В соответствии с этим получим новое распределение состояний по классам.

8. Лемма о разрастании для автоматных языков. Примеры неавтоматных языков.

Лемма: (о накачке (разрастании))


Пусть L - автоматный язык, $|L| = \infty$. Тогда:

$$\exists P \forall w \in L : |w| > P (\exists x, y, z : w = xyz, |xy| \leq P, |y| \neq 0 : \forall k \in \mathbb{N} : xy^kz \in L)$$

Идея доказательства:

- 1) Рассмотрим НКА с однобуквенными переходами M .
- 2) Взять $P = |Q|$ (количество состояний), найти первый "цикл".

Рассмотрим $w \in L : |w| > P \Rightarrow$ То по принципу Дирихле, найдётся состояние q , которые мы посетили дважды. Образовался цикл ($w = xyz$):



1. $|xy| \leq P = |Q|$: допустим, что $|xy| > P = |Q|$, тогда в xy нашёлся бы цикл, где q не будет являться первым пересечением;
2. $|y| \neq 0$, так как среди переходов в автомате M встречаются только однобуквенные, то существует хотя бы одно состояние $q_{new} \neq q$, которое будет посещено.

Слово xy^kz принадлежит языку L для любого $k \in \mathbb{N}$, так как цикл, соответствующий y , может быть повторён k раз. ■

Пример: Язык $\{a^n b^n | n \in \mathbb{N}\}$ не является автоматным.

▲ Воспользуемся отрицанием леммы о разрастании:

$$\forall p \exists w \in L : |w| \geq P \forall x, y, z : w = xyz, |xy| \leq P, |y| \neq 0 : \forall k \in \mathbb{N} : xy^kz \notin L$$

. Возьмем произвольное p и рассмотрим $w = a^p b^p$. Тогда

$$w = xyz : |xy| \leq p, |y| \geq 0 \Rightarrow x = a^k, y = a^l, l > 0 \rightarrow z = a^{p-k-l} b^p$$

Рассмотрим $xy^2z = a^k a^{2l} a^{p-k-l} b^p = a^{p+l} b^p$. Так как $p + l \neq p$, значит $xy^2z \notin L$ ■

9. Алгоритм проверки равенства регулярных выражений. Теорема Майхилла-Нероуда.

Лемма (из билета 6): Для любых $u \in \Sigma^*$, $a \in \Sigma$ верно, что $\Delta([u], a) = [ua]$

▲ $u \sim_L v \implies \forall w' (uw' \in L \iff vw' \in L) \implies \forall w (uaw \in L \iff vaw \in L) \iff ua \sim_L va$ ■

Лемма: Для любых $u, v \in \Sigma^*$ верно, что $\Delta([u], v) = [uv]$

▲ Индукция по $|v|$. База:

$$v = \varepsilon \implies \Delta([u], \varepsilon) = [u] = [u\varepsilon]$$

$$v = a \implies \Delta([u], a) = [ua] \text{ — по предыдущей лемме.}$$

Шаг: $v = v'a$

$$\Delta([u], v'a) = \Delta(\Delta([u], v'), a) = \Delta([uv'], a) = [uv'a] = [uv]$$

■

Теорема Майхилла-Нероуда: Язык L является автоматным тогда и только тогда, когда Σ^*/\sim_L содержит конечное количество классов эквивалентности.

▲

\implies Так как L является автоматным, то для него существует минимальный ПДКА, $|\Sigma^*/\sim_L| = |Q|$, Q - конечно

\Leftarrow Множество Σ^*/\sim_L конечно. Построим канонический ПДКА $M_0 = \langle Q, \Sigma, \Delta, [\varepsilon], F \rangle$, где $Q = \Sigma^*/\sim_L$, $F = \{[w] \mid w \in L\}$, $\Delta = \{\langle [w], a \rangle \rightarrow [wa] \mid w \in \Sigma^*, a \in \Sigma\}$. Докажем, что $L(M_0) = L$.

$$w \in L(M_0) \iff \Delta([\varepsilon], w) \in F \iff [w] \in F \iff \exists u \in L (w \sim_L u) \iff w \in L.$$

Заметим, что если $u \in L$, $w \notin L$ то $u \not\sim w$. Автомат построен. ■

Алгоритм проверки регулярных выражений на равенство

Пусть R_1 и R_2 — регулярные выражения. Построим по ним минимальные ПДКА M_1 и M_2 соответственно. По теореме о существовании и единственности минимального ПДКА для автоматного языка $L(M)$ минимальный ПДКА единственен с точности до изоморфизма. Если M_1 и M_2 изоморфны, то регулярные выражения равны, иначе нет.

2. КС-грамматики и МП-автоматы

10. Иерархия Хомского. Праволинейные грамматики. Праволинейные языки. Теорема о совпадении классов автоматных и праволинейных языков.

Иерархия Хомского

$$A, B \in N, \alpha, \varphi, \psi \in (N \cup \Sigma)^*, w \in \Sigma^*$$

Грамматики	Правила	Автоматы
Праволинейные	$A \rightarrow wB, A \rightarrow w$	НКА
Контекстно-свободные	$A \rightarrow \alpha$	Автоматы с магазинной памятью
Контекстно-зависимые	$\varphi A \psi \rightarrow \varphi \alpha \psi$	Линейно-ограниченные недетерминированные автоматы, машины Тьюринга
Порождающие	Любые	Машины Тьюринга

Порождающие грамматики

Определение: Порождающая грамматика: $G = \{N, \Sigma, P, S\}$, где:

- 1) N – множество вспомогательных (нетерминальных) символов, $|N| < \infty$.
- 2) Σ – алфавит – множество (терминальных) символов, $|\Sigma| < \infty, \Sigma \cap N = \emptyset$.
- 3) $S \in N$ – стартовый нетерминал
- 4) $P \subset (N \cup \Sigma)^+ \times (N \cup \Sigma)^*$ – множество правил, $|P| < \infty$.

Правила грамматики грамматики задаются следующим образом:

$$\alpha \rightarrow \beta \in P, \alpha \in (N \cup \Sigma)^+, \beta \in (N \cup \Sigma)^*$$

То есть α должен содержать хотя бы один символ — либо терминальный, либо нетерминальный, а β может быть равным ε , то есть пустому слову.

В следующих определениях $G = \{N, \Sigma, P, S\}$ – порождающая грамматика.

Определение: Наименьшее рефлексивное транзитивное отношение \vdash_G называется *отношением выводимости* в грамматике G , если

$$\forall (\alpha \rightarrow \beta) \in P, \forall \varphi, \psi \in (N \cup \Sigma)^* : \varphi \alpha \psi \vdash_G \varphi \beta \psi$$

По сути, это операция замены левой части на правую часть несколько раз, возможно, нуль.

Определение: Слово $w \in \Sigma^*$ называется *выводимым* в грамматике G , если $S \vdash_G w$, то есть из стартового символа достижимо слово w .

Определение: Язык L распознаётся грамматикой G , если $L = \{w \in \Sigma^* \mid S \vdash_G w\}$, то есть язык L состоит из таких слов, которые выводимы в грамматике G . Если L распознаётся грамматикой G , то его обозначают как $L(G)$.

Праволинейные грамматики и праволинейные языки

Определение: Грамматика G называется праволинейной, если правила из P имеют вид либо $A \rightarrow wB$, либо $A \rightarrow w$, где A, B — нетерминальные символы, то есть $A, B \in N$, и $w \in \Sigma^*$.

Определение: Язык $L(G)$ называется праволинейным, если грамматика G , которой распознаётся (задаётся) язык L , является праволинейной.

Теорема о совпадении классов автоматных и праволинейных языков

Теорема: Множество автоматных языков равно множеству языков, задаваемых праволинейными граммами.

▲ **Грамматика \rightarrow Автомат:** Состояния в автомате = нетерминалы в грамматике + сток

Пусть дан язык, задаваемый праволинейной грамматикой: $\mathcal{L} = \mathcal{L}(G)$, $G = \{N, \Sigma, P, S\}$

Построим $M = \{N \cup \{q_f\}, \Sigma, \Delta', S, \{q_f\}\}$, где

$\Delta' = \{\{A, w\} \rightarrow B, \text{ если } A \rightarrow wB \in P\} \cup \{\{A, w\} \rightarrow q_f, \text{ если } A \rightarrow w \in P\}$

Надо показать, что $\mathcal{L}(G) = \mathcal{L}(M)$

$\mathcal{L}(G) \subset \mathcal{L}(M)$: Индукция по длине вывода грамматики (количество \vdash)

$$w \in \mathcal{L}(G) \Rightarrow S \vdash_G w \Rightarrow \dots \Rightarrow \{S, w\} \vdash_M \{q_f, \varepsilon\} \Rightarrow w \in \mathcal{L}(M) \quad (*)$$

Покажем, что если $C \vdash_G wD$ (за k шагов), то $\{C, w\} \vdash_M \{D, \varepsilon\}$.

Индукция по k :

$k = 0$:

$$C \vdash_G C \Rightarrow w = \varepsilon \Rightarrow \{C, \varepsilon\} \vdash_M \{C, \varepsilon\}$$

Переход:

$$C \vdash wD \text{ за } k \text{ шагов} \Rightarrow \exists E, u, v : C \vdash_G uE \text{ за } k-1 \text{ шаг}, uE \vdash_G uvD \text{ за } 1 \text{ шаг} (w = uv)$$

Тогда по предположению индукции

$$\{C, u\} \vdash_M \{E, \varepsilon\}, \{E, v\} \vdash_M \{D, \varepsilon\} \Rightarrow \{C, uv\} \vdash_M \{D, \varepsilon\} \text{ (по транзитивности)}$$

Если $C \vdash_G w$, то $\{C, w\} \vdash_M \{q_f, \varepsilon\}$

Так как из q_f нет переходов, то $\exists E : C \vdash_G uE$ (за $k-1$), $uE \vdash_G uv$ (за 1) ($E \rightarrow v \in P$)

Тогда $\{C, uv\} \vdash_M \{E, \varepsilon\} \vdash \{q_f, \varepsilon\}$

Чтобы доказать (*), достаточно вместо C подставить S

$$\{S, w\} \vdash \{q_f, \varepsilon\} \Rightarrow w \in \mathcal{L}(M)$$

$$\underline{\mathcal{L}(M) \subset \mathcal{L}(G)}: w \in \mathcal{L}(M) \Rightarrow \{S, w\} \vdash_M \{q_f, \varepsilon\}$$

Покажем, что если $\{C, w\} \vdash_M \{D, \varepsilon\}$, то $C \vdash_G wD$

Индукция по длине пути в автомате:

База: $k = 0$

$$\{C, w\} \vdash_M \{D, \varepsilon\}, \quad C = D, w = \varepsilon \Rightarrow C \vdash_G C$$

Переход:

$$\exists E, u : \langle C, w \rangle \vdash_M \langle E, u \rangle \vdash_M \{D, \varepsilon\}$$

$$w = uv \Rightarrow \text{ по предположению индукции: } C \vdash_G uE, E \vdash vD \Rightarrow C \vdash_G uvD = wD$$

Так как из q_f нет переходов, то $\{S, w\} \vdash \{q_f, \varepsilon\} \Rightarrow$

$$\exists E, u, v : \{S, uv\} \vdash_M \{E, v\} \vdash_M \{q_f, \varepsilon\} \Rightarrow \{S, u\} \vdash \{E, \varepsilon\} \Rightarrow S \vdash_G uE$$

$$\{E, v\} \vdash_M \{q_f, \varepsilon\} \Rightarrow E \vdash_G v$$

$$S \vdash_G uE, E \vdash_G v \Rightarrow S \vdash_G uv$$

Автомат \rightarrow Грамматика: Идея: возьмём автомат с 1 завершающим состоянием q_{stock} (и из этого q_{stock} нет переходов)

$$M = \{Q, \Sigma, \Delta, q_0, \{q_{stock}\}\}$$

$$G = \{Q \setminus \{q_{stock}\}, \Sigma, P, q_0\}$$

$$P = \{q_1 \vdash wq_2 \mid q_2 \neq q_{stock} \text{ и } \{q_1, w\} \rightarrow q_2 \in \Delta\} \cup \{q_1 \rightarrow w \mid \{q_1, w\} \rightarrow q_{stock} \in \Delta\}$$

Доказательство аналогично *Грамматика \rightarrow Автомат*

11. Контекстно-свободные грамматики и языки. Примеры контекстно-свободных языков. Замкнутость и незамкнутость КС-языков относительно теоретико-множественных операций (можно пользоваться примерами не КС-языков).

Определение: Контекстно-свободная грамматика - грамматика, все правила которой имеют вид $A \rightarrow \alpha$, где $A \in N, \alpha \in (N \cup \Sigma)^*$. Язык называют контекстно-свободным, если он задается контекстно-свободной грамматикой.

Пример: КС-язык: $L = \{a^n b^m c^m\}$. Грамматика: $S \rightarrow AT, A \rightarrow aA, A \rightarrow \varepsilon, T \rightarrow bTc, T \rightarrow \varepsilon$

Пример: Не КС-язык (понадобится для доказательств): $L = \{a^n b^n c^n\}$

▲ Зафиксируем p в лемме о разрастании. Рассмотрим $w = a^p b^p c^p = xuyvz, |uv| > 0, |uyv| \leq p$. Заметим, что в uyv и uv не может быть трех разных букв из a, b, c . Не умаляя общности $|uyv|_c = 0, |uyv|_b > 0$. Рассмотрим $k = 2$:

$$|w'|_b = |xu^2yv^2z|_b = |xuyvz|_b + |uv|_b > p$$

$$|xu^2yv^2z|_c = p + |uv|_c = p$$

Следовательно, $|w'|_b \neq |w'|_c$, а значит w' не лежит в языке и выполнено отрицание леммы о разрастании, то есть язык не является КС ■

Утверждение: КС-грамматики замкнуты относительно объединения и конкатенации

- ▲ 1. Объединение: конструктивно построим объединение грамматик: создадим стартовую вершину S' и два правила $S' \rightarrow S_1, S' \rightarrow S_2$, где S_i - стартовый нетерминал первой или второй грамматики соответственно. Если нетерминальные символы в грамматиках совпадают переименуем их в одной из грамматик.
2. Конкатенация: аналогично, построим КС-грамматику для языка $L_1 L_2$, добавив правило $(S' \rightarrow S_1 S_2)$. ■

Утверждение: КС-грамматики не замкнуты относительно пересечения и дополнения

- ▲ 1. Пересечение:

$$L_1 = \{a^n b^m c^m\},$$

$$L_2 = \{a^n b^n c^m\}$$

$$L_1 \cap L_2 = \{a^n b^n c^n\} - \text{не КС-язык}$$

2. Дополнение:

$$L = \{a^n b^n c^n\} - \text{не КС-язык}$$

$$\bar{L} = \{\text{easy cases}\} \cup \{a^k b^l c^m | k \neq l \vee l \neq m \vee k \neq m\}$$

Оба языка из объединения - КС $\Rightarrow \bar{L}$ - КС. Но $L = \bar{\bar{L}}$ не КС \Rightarrow множество КС языков не замкнуто относительно дополнения ■

12. Устранение бесполезных вспомогательных символов и eps-правил для КС-грамматик.

Определение: Символ $Y \in N$ называется порождающим, если существует слово $w \in \Sigma^*$, такое что $Y \vdash w$.

Определение: Символ $D \in N$ называется достижимым, если существуют некоторые $\varphi, \psi \in (N \cup \Sigma)^*$, такие что $S \vdash \varphi D \psi$.

Определение: Символ $U \in N$ называется бесполезным, если он непорождающий или недостижимый.

Определение: Символ $E \in N$ называется ε -порождающим, если $E \vdash \varepsilon$.

Утверждение: Для любой контекстно-свободной грамматики существует эквивалентная КС-грамматика без бесполезных символов.

▲ Приведём алгоритм преобразования КС-грамматики: сначала найдём непорождающие символы, удалим их из грамматики, затем найдём и удалим недостижимые символы.

Пусть G_1 — грамматика, преобразованная из G путём удаления непорождающих символов и всех правил, содержащих непорождающие символы. Покажем, почему $L(G) = L(G_1)$. $L(G_1) \subset L(G)$, так как количество правил уменьшается. Пусть $w \in L(G) \setminus L(G_1)$, тогда в дереве вывода есть непорождающий символ C :

$$S \vdash \varphi C \psi \vdash w, w = xyz$$

Но $\varphi \vdash x$, $C \vdash y$, $\psi \vdash z$, откуда C — порождающий символ. Противоречие.

Пусть G_2 — грамматика, преобразованная из G_1 путём удаления всех недостижимых символов и правил, содержащих их. Покажем, почему $L(G_1) = L(G_2)$. $L(G_2) \subset L(G_1)$, так как количество правил уменьшается. Пусть $w \in L(G_1) \setminus L(G_2)$, тогда существует недостижимый символ D , что $S \vdash \varphi D \psi \vdash w$, но тогда D по определению является достижимым. Противоречие.

Проверим, что не появилось новых непорождающих символов. Пусть B — непорождающий символ в G_2 , значит B достижим в G_1 . Тогда B — порождающий символ в G_1 , то есть $B \vdash_{G_1} u$. Так как B стал непорождающим после удаления недостижимых символов, значит, что на пути вывода $B \vdash u$ был недостижимый символ C , чего не может быть так как есть путь $S \rightarrow B \rightarrow C$ — противоречие ■

Про удаление ε -порождающих символов см. билет 13

13. Нормальная форма Хомского для КС-грамматик. Алгоритм приведения к нормальной форме Хомского.

Определение: КС-грамматика находится в нормальной форме Хомского, если все правила имеют такой и только такой вид:

1. $A \rightarrow a$ ($A \in N$, $a \in \Sigma$);
2. $A \rightarrow BC$ ($B, C \in N$; $B, C \neq S$);
3. $S \rightarrow \varepsilon$.

Утверждение: Любую КС-грамматику можно привести к нормальной форме Хомского с помощью алгоритма, который состоит из следующих шагов:

1. Удаление непорождающих символов
 2. Удаление недостижимых символов
 3. Удаление смешанных правил $D \rightarrow aBc$
 4. Удаление длинных правил $A \rightarrow A_1A_2A_3A_4$
 5. Удаление ε -порождающих символов
 6. Обработка пустого слова
 7. Удаление унарных (одиночных) правил $A \rightarrow B$
- 1-2. После удаления непорождающих и недостижимых символов будет получена эквивалентная грамматика. Подробное доказательство этого есть в вопросе 12. Обозначим полученную грамматику за G_2 .

3. Для удаления смешанных правил сделаем замену правила вида $A \rightarrow dBcEf$ на правила следующего вида: $A \rightarrow DBCEF$, $D \rightarrow d$, $C \rightarrow c$, $F \rightarrow f$.

Обозначим полученную грамматику за G_3 . Покажем, что $w \in L(G_2) \Leftrightarrow w \in L(G_3)$. В основе доказательства лежит идея, что в дереве вывода нетерминальные символы можно выводить в любом порядке.

\Rightarrow

$$\begin{aligned} A \vdash_1 dBcEf \vdash dw_Bcw_Ef \ (G_2) \\ A \vdash DBCEF \vdash dBcEf \vdash dw_Bcw_Ef \ (G_3) \end{aligned}$$

\Leftarrow Если в дереве вывода встречается $A \vdash DBCEF$, то раскрываем в первую очередь правила вида $D \rightarrow d$, а потом повторяем те же действия что в грамматике G_2

4. Удалим длинные правила вида $B \rightarrow A_1A_2 \dots A_n$ с помощью замены на правила следующего вида:

$$B \rightarrow A_1 B_1 \quad B_1 \rightarrow A_2 B_2 \quad B_2 \rightarrow A_3 B_3 \quad \dots \quad B_{n-1} \rightarrow A_{n-1} A_n$$

Обозначим полученную грамматику за G_4 . Покажем, что $w \in L(G_3) \Leftrightarrow w \in (G_4)$.

\Rightarrow Пусть $w \in L(G_3)$. Тогда $S \vdash \varphi B \psi \vdash_1 \varphi A_1 A_2 \dots A_n \psi \vdash w$. Посмотрим, что происходит в G_4 :

$$S \vdash \varphi B \psi \vdash \varphi A_1 B_1 \psi \vdash \varphi A_1 A_2 B_2 \psi \vdash \dots \vdash \varphi A_1 A_2 \dots A_{n-2} B_{n-1} \psi \vdash \varphi A_1 \dots A_n \psi \vdash w$$

\Leftarrow Пусть $w \in L(G_4)$. Рассмотрим вывод $S \vdash w$. Возможны два варианта:

1. B_k не встречается на пути вывода. Тогда слово выводимо и в G_4 , и в G_3 ;
2. B_k встречается на пути вывода. Тогда встречаются и все нетерминалы вида B_1, \dots, B_{n-1} по построению правил. Доказательство корректности аналогично доказательству в другую сторону.


5. Теперь остались правила вида:

$$A \rightarrow a \quad A \rightarrow BC \quad A \rightarrow B \quad A \rightarrow \varepsilon$$

Будем удалять ε правила:

1. Если $A \rightarrow BC$ и $C \vdash \varepsilon$, то добавим $A \rightarrow B$
2. Если $A \rightarrow BC$ и $B \vdash \varepsilon$, то добавим $A \rightarrow C$

Затем просто удаляем правила $A \rightarrow \varepsilon$. Получили грамматику G_5 . Покажем корректность, то есть $w \in L(G_4) \Leftrightarrow w \in L(G_5)$ и $w \neq \varepsilon$.



▲ \Rightarrow Пусть $w \in L(G_4)$. Выделим поддеревья максимальной мощности из которых выводится ε в дереве вывода w . Рассмотрим корень такого поддерева. Он не мог быть получен по правилу вида $C \rightarrow B$, так как тогда $C \vdash B \vdash \varepsilon$ и C можно было бы включить в это поддерево, что противоречило бы максимальной. Поэтому корень B был получен по правилу $C \rightarrow BD$ или $C \rightarrow DB$ (без ограничения общности рассмотрим первое). Тогда в G_4 : $C \vdash_1 BD \vdash \varepsilon u = u$, а в G_5 : $C \vdash_1 D \vdash u$, то есть ничего не поменялось $\Rightarrow w \in L(G_5)$

\Leftarrow Пусть $w \in L(G_5)$. Рассмотрим правила вида $C \rightarrow D$ в дереве вывода w в G_5 , которых не было в G_4 . Значит в G_4 было одно из правил $C \rightarrow BD, C \rightarrow DB$ и $B \vdash \varepsilon \Rightarrow w \in L(G_4)$ ■

6. Если $S \vdash \varepsilon$, то построим грамматику G_6 следующим образом:

1. S' — новый стартовый нетерминал;
2. $S' \rightarrow S$ — новое правило;
3. Если $S \vdash \varepsilon$, то $S' \rightarrow \varepsilon$ — новое правило.

Данная грамматика будет эквивалентной. Этим шагом мы еще и частично приблизились ко второму пункту в определении НФ Хомского (не зацикливаемся на старте)

7. Рассмотрим последовательности правил:

$$\begin{aligned} B &\rightarrow B_1 \rightarrow B_2 \rightarrow \dots \rightarrow B_n \rightarrow CD \\ B &\rightarrow B_1 \rightarrow B_2 \rightarrow \dots \rightarrow B_n \rightarrow a \end{aligned}$$

Удалим унарные одиночные правила, заменим последовательности правил на $B \rightarrow CD$ и $B \rightarrow a$ соответственно (транзитивное замыкание). Обозначим полученную грамматику за G_7 .

Покажем, что $L(G_6) = L(G_7)$. (= док-ву удаления ε -переходов в автомате).

\Leftarrow Для всех правил вида $B \rightarrow a$ или $B \rightarrow CD$ верно, что $B \vdash_{G_6} a$, $B \vdash_{G_6} CD$. Никаких новых выводов добавлено не было, тем самым $L(G_7) \subseteq L(G_6)$.

\Rightarrow Покажем, что $B \vdash_{G_6} w \Rightarrow B \vdash_{G_7} w$ индукцией по длине вывода.

База. Вывод за один шаг: $B \vdash_{G_6,1} w \Rightarrow (B \rightarrow w) \in P_{G_6}, w \in \Sigma \Rightarrow (B \rightarrow w) \in P_{G_7} \Rightarrow B \vdash_{G_7,1} w$.

Переход. Добавленное правило имеет вид $B \rightarrow C_1 \dots C_n$, где $n \in \{1, 2\}$, $B \rightarrow C_1 \dots C_n \vdash_{G_6} w_1 \dots w_n$, по предположению индукции $C_i \vdash_{G_7} w_i$.

Пусть $n = 2$. Тогда правило имеет вид $B \rightarrow CD$, $B \vdash_{G_7} CD \vdash_{G_7} w_1 w_2$.

Пусть $n = 1$. Тогда вывод начинается с правила $B \rightarrow C_1$. Рассмотрим первое правило вывода, не являющееся одиночным. Тогда:

1. $B \vdash C_1 \vdash C_2 \vdash \dots \vdash C_m \vdash a$, $a \in \Sigma$, тогда по построению существует правило $B \rightarrow a$, $B \vdash_{G_7} a$;
2. $B \vdash C_1 \vdash C_2 \vdash \dots \vdash CD \vdash w_1 w_2$. По построению существует правило $B \rightarrow CD$, по предположению индукции $B \vdash_{G_7} CD \vdash w_1 w_2$.

Построенная грамматика G_7 — грамматика в нормальной форме Хомского.

14. Алгоритм Кока-Янгера-Касами синтаксического разбора для КС-грамматик.

Алгоритм Кока-Янгера-Касами принимает на вход грамматику G в нормальной форме Хомского и слово w . В качестве выхода выдаётся информация, принадлежит ли слово w языку L , который задаётся грамматикой G .

Идея алгоритма

Пусть $G = \langle N, \Sigma, P, S \rangle$ и $|w| = n$.

Будем решать задачу динамическим программированием. Заведём трехмерный массив d размером $|N| \times n \times n$, состоящий из логических значений, и $d[A][i][j] = \text{true}$ тогда и только тогда, когда из нетерминала A правилами грамматики можно вывести подстроку $w[i \dots j]$.

Рассмотрим все пары $\{ \langle j, i \rangle \mid j - i = m \}$, где m – константа и $m < n$.

1) $i = j$. Инициализируем массив для всех нетерминалов, из которых выводится какой-либо символ строки w . В таком случае $d[A][i][i] = \text{true}$, если в грамматике G присутствует правило $A \rightarrow w[i]$. Иначе $d[A][i][i] = \text{false}$.

2) $i \neq j$. Значения для всех нетерминалов и пар $\{ \langle j', i' \rangle \mid j' - i' < m \}$ уже вычислены, поэтому

$$d[A][i][j] = \bigvee_{A \rightarrow BC} \bigvee_{k=i}^{j-1} d[B][i][k] \wedge d[C][k+1][j]$$

То есть, подстроку $w[i \dots j]$ можно вывести из нетерминала A , если существует продукция вида $A \rightarrow BC$ и такое k , что подстрока $w[i \dots k]$ выводима из B , а подстрока $w[k+1 \dots j]$ выводится из C . Ответом будет значение $d[S][1][n]$.

Доказательство корректности

Проведём индукцию по длине слова.

База. Пусть $j = i$. Тогда $dp[A][i][j] = \text{True}$ появилась на этапе инициализации, что по построению равносильно тому, что правило $(A \rightarrow w[i]) \in P$, что эквивалентно тому, что $A \vdash w[i : j]$, $j = i$, то есть $A \vdash w[i]$.

Переход. Пусть $dp[A][i][j] = \text{True}$. Тогда по построению и предположению индукции существуют число k и нетерминальные символы B и C , такие что $A \vdash_1 BC$, $B \vdash w[i : k]$, $C \vdash w[k+1 : j]$, откуда $dp[B][i][k] = dp[C][k+1][j] = \text{True}$, так как $A \vdash_1 BC$, то $(A \rightarrow BC) \in P$, $A \vdash w[i : j]$.

Асимптотика

Обработка правил вида $A \rightarrow w[i]$ выполняется за $O(n \cdot |P|)$.

Проход по всем подстрокам выполняется за $O(n^2)$. В обработке одной подстроки присутствует цикл по всем правилам вывода и по всем разбиениям на две подстроки, следовательно обработка работает за $O(n \cdot |P|)$. В итоге получаем конечную сложность $O(n^3 \cdot |P|)$.

15. Лемма о разрастании для КС-языков. Примеры языков, не являющихся КС-языками.


Лемма о разрастании для КС-языков

Лемма: Пусть L – КС-язык. Тогда существует p , такое что для любого слова $w \in L$, длина которого не меньше, чем p , существуют такие слова x, u, y, v, z , принадлежащие Σ^* , что $w = xuyvz$, $|uv| > 0$, $|uyv| \leq p$, что для любого $k \in \mathbb{N}$ выполняется, что $xu^k y v^k z \in L$.

Кванторная версия:

$\exists p : \forall w \in L : |w| \geq p : \exists x, u, y, v, z \in \Sigma^* : w = xuyvz, |uv| > 0, |uyv| \leq p : \forall k \in \mathbb{N} : xu^k y v^k z \in L$

▲ Рассмотрим грамматику G в нормальной форме Хомского: $L = L(G)$. Выберем $p = 2^{|N|}$, где $|N|$ – количество нетерминальных символов. Тогда $|w| \geq p = 2^{|N|}$. Дерево вывода является бинарным деревом, и тогда существует «ветвь» дерева вывода уровня хотя бы $|N|$ (уровни в 0 индексации). Рассмотрим «ветвь» максимальной глубины: в ней количество нетерминалов будет хотя бы $|N| + 1$. Тогда по принципу Дирихле, существует нетерминал A , такой что $S \vdash xAz \vdash xuAvz \vdash xuyvz$ и $A \vdash uAv$, который повторяется не менее двух раз. Среди всех возможных нетерминалов A выберем тот, который находится ниже всех, то есть его глубина относительно корня наибольшая.



Покажем, что $|uyv| \leq p = 2^{|N|}$. Пусть $|uyv| > p = 2^{|N|}$, тогда для дерева со стартом в A можно сделать те же самые операции, значит, существует уровень, который больше $|N|$, значит, существует в поддереве пара $B \vdash B$, и A – не самый глубокий нетерминал.

Покажем, что $|uv| > 0$. Для любого нетерминального символа $C \in N$ верно, что C не является ε -порождающим. Рассмотрим D такой, что $D \vdash KA$ (за один шаг), $K \vdash r$, где r – суффикс u , $|r| > 0$. Отсюда следует, что $|uv| \geq |u| \geq |r| > 0$. ■

Пример: Не КС-язык: $L = \{a^n b^n c^n\}$

▲ Зафиксируем p в лемме о разрастании. Рассмотрим $w = a^p b^p c^p = xuyvz$, $|uv| > 0$, $|uyv| \leq p$. Заметим, что в uyv и uv не может быть трех разных букв из a, b, c . Не умаляя общности $|uyv|_c = 0$, $|uyv|_b > 0$. Рассмотрим $k = 2$:

$$|w'|_b = |xu^2 y v^2 z|_b = |xuyvz|_b + |uv|_b > p$$

$$|xu^2 y v^2 z|_c = p + |uv|_c = p$$

Следовательно, $|w'|_b \neq |w'|_c$, а значит w' не лежит в языке и выполнено отрицание леммы о разрастании, то есть язык не является КС ■

16. Автоматы с магазинной памятью (МП-автоматы). Различные варианты определений. Языки, распознаваемые МП-автоматами.

Определение: Автомат с магазинной памятью (МП-автомат) — кортеж $M = \langle Q, \Sigma, \Gamma, \Delta, q_0, F \rangle$, где:

1. Q — множество состояний, Q — конечное множество, то есть $|Q| < \infty$;
2. Σ — алфавит, $|\Sigma| < \infty$;
3. Γ — стековый алфавит, $|\Gamma| < \infty$, $\Gamma \cap \Sigma = \emptyset$;
4. $\Delta \subset (Q \times \Sigma^* \times \Gamma^*) \times (Q \times \Gamma^*)$ — множество переходов, $|\Delta| < \infty$;
5. $q_0 \in Q$ — стартовое состояние;
6. $F \subset Q$ — множество завершающих состояний.

Переходы имеют вид $\langle q_1, w, \alpha \rangle \rightarrow \langle q_2, \beta \rangle$, $w \in \Sigma^*$, $\alpha \in \Gamma^*$, то есть когда находимся в состоянии q_1 , снимаем со стека слово α , стек растёт слева направо, читаем слово w , переходим в состояние q_2 , добавляем на стек слово β .

Определение: Конфигурация МП-автомата M — кортеж $\langle q, u, \gamma \rangle$, где $q \in Q$, $u \in \Sigma^*$, $\gamma \in \Gamma^*$.


Определение: Отношение выводимости \vdash — наименьшее рефлексивное транзитивное отношение, что для любого перехода $(\langle q_1, u, \alpha \rangle \rightarrow \langle q_2, \beta \rangle) \in \Delta$ выполнено следующее:

$$\forall v \in \Sigma^*, \eta \in \Gamma^* : \langle q_1, uv, \eta\alpha \rangle \vdash \langle q_2, v, \eta\beta \rangle$$

Языки, распознаваемые МП-автоматами

Определение: Пусть M — МП-автомат, язык $L(M)$, распознаваемый МП-автоматом M — множество $\{w \in \Sigma^* | \exists q \in F : \langle q_0, w, \varepsilon \rangle \vdash \langle q, \varepsilon, \varepsilon \rangle\}$.

Пример: Язык правильных скобочных последовательностей распознаётся следующим МП-автоматом:




Упрощения МП-автоматов

Утверждение: Для любого МП-автомата существует эквивалентный МП-автомат, для которого выполнено соотношение:

$$\forall (\langle q_1, u, \alpha \rangle \rightarrow \langle q_2, \beta \rangle) \in \Delta : |u| \leq 1, |\alpha| + |\beta| \leq 1$$

▲




■

Утверждение: Для любого МП-автомата существует эквивалентный МП-автомат, для которого выполнено соотношение:

$$\forall (\langle q_1, u, \alpha \rangle \rightarrow \langle q_2, \beta \rangle) \in \Delta : |u| \leq 1, |\alpha| + |\beta| = 1$$

▲



■

17. Совпадение классов КС-языков и языков, распознаваемых МП-автоматами: построение автомата по грамматике.

В вопросах 16 и 17 предлагается доказать в одну из сторон следующую теорему:


Теорема: Язык L является МП-автоматным тогда и только тогда, когда L является контекстно-свободным.

Gram \Rightarrow Automaton

▲ Идея: снимаем со стека левую часть правила, добавляем правую часть правила

Рассмотрим контекстно-свободную грамматику $G = \langle N, \Sigma, P, S \rangle$. Автомат строим следующим образом: q_0 — стартовое (начальное) состояние, q_1 — единственное завершающее состояние, $Q = \{q_0, q_1\}$. Переходы из q_1 в q_1 имеют вид либо $\langle q_1, a, a \rangle \rightarrow \langle q_1, \varepsilon \rangle$, если a — некоторый терминальный символ, либо $\langle q_1, \varepsilon, S \rangle \rightarrow \langle q_1, SbSa \rangle$, если существует правило вида $S \rightarrow aSbS$, где $S \in N$. Заметим, что при обработке правил, где левая часть — некоторый нетерминал, мы добавляем в стек *развёрнутую правую часть* правила.

Чтобы было видно, что происходит, приведём пример. Пусть правила КС-грамматики G следующие: $(S \rightarrow \varepsilon), (S \rightarrow aSbS)$. Тогда МП-автомат по КС-грамматике будет таким:



Докажем следующую лемму:

Лемма: $A \vdash w \iff \langle q_1, w, A \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle$

Докажем индукцией по длине дерева вывода (количеству рёбер в дереве). Считаем её равной k .

База. $k = 1$, $A \vdash_1 w$. Пусть $w = w_1 w_2 \dots w_n$. Так как $A \rightarrow w_1 \dots w_n$, то $\langle q_1, \varepsilon, A \rangle \rightarrow \langle q_1, w^R \rangle$. Значит:

$$\begin{aligned} \langle q_1, w, A \rangle &\vdash \langle q_1, w, w_n w_{n-1} \dots w_1 \rangle \vdash \\ &\vdash \langle q_1, w_2 \dots w_n, w_n w_{n-1} \dots w_2 \rangle \vdash \\ &\vdash \langle q_1, w_3 \dots w_n, w_n \dots w_3 \rangle \vdash \dots \\ &\vdash \langle q_1, w_n, w_n \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle \end{aligned}$$

Переход. Посмотрим на первое раскрытие: $A \vdash_1 \alpha \vdash w$. Здесь $\alpha = \alpha_1 \dots \alpha_n \vdash w_1 \dots w_n = w$, $\alpha_i \in N \cup \Sigma$. Тогда $\langle q_1, w, A \rangle \vdash \langle q_1, w, \alpha_n \dots \alpha_1 \rangle$.

Если $\alpha_n \in N$, то тогда $\alpha_n \vdash w_n$, и по предположению индукции $\langle q_1, w_n, \alpha_n \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle$.

Если $\alpha_n \in \Sigma$, то $\alpha_n \vdash w_n$, $\alpha_n = w_n$, и тогда $\langle q_1, w_n, w_n \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle$, так как это правило грамматики.

В итоге:

$$\langle q_1, w, A \rangle \vdash \langle q_1, w, \alpha_n \dots \alpha_1 \rangle \vdash \langle q_1, w_1 \dots w_n, \alpha_n \dots \alpha_1 \rangle \vdash \langle q_1, w_2 \dots w_n, \alpha_n \dots \alpha_2 \rangle \vdash \dots \vdash \langle q_1, w_n, \alpha_n \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle.$$

Теперь нужно показать в обратную сторону: если $\langle q_1, w, A \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle$, то $A \vdash w$. Это сделаем с помощью индукции по количеству переходов.

База. Пусть всего один переход, тогда $A \in \Sigma$, и $\langle q_1, w, A \rangle \vdash_1 \langle q_1, \varepsilon, \varepsilon \rangle$, откуда $w = A$, и $A \vdash w$, так как \vdash обладает свойством рефлексивности.

Переход. $\langle q_1, w, A \rangle \vdash_k \langle q_1, \varepsilon, \varepsilon \rangle$, где $k > 1$. Тогда $A \in N$, откуда если $A \rightarrow \alpha_1 \dots \alpha_n$, где $\alpha_m \in (N \cup \Sigma)$, то:

$$\langle q_1, w, A \rangle \vdash_1 \langle q_1, w, \alpha_n \dots \alpha_1 \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle$$

Замечание: За один шаг мы снимаем ровно один элемент со стека:

$$\begin{array}{c} \alpha_1 \rightarrow \beta_1 \\ \alpha_2 \rightarrow \beta_2 \\ \vdots \\ \alpha_n \rightarrow \beta_n \end{array}$$

Пусть $\alpha_1 \rightarrow \beta_1$, $\alpha_1 \in N$, $\langle q_1, w, \alpha_n \dots \alpha_1 \rangle \vdash_1 \langle q_1, w, \alpha_n \dots \alpha_2 \beta_1^R \rangle$. Дождёмся, пока на стеке останется $\alpha_n \dots \alpha_2$: так как в конце стек пустой и мы считаем ровно 1 символ. Тогда в этом моменте:

$$\langle q_1, w, \alpha_n \dots \alpha_1 \rangle \vdash \langle q_1, w', \alpha_n \dots \alpha_2 \rangle \implies \exists w_1 : w = w_1 w' : \langle q_1, w_1, \alpha_1 \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle \xRightarrow{\text{hypothesis}} \alpha_1 \vdash w_1$$

По аналогии, $\alpha_m \vdash w_m$ для любого $m = \overline{1, n}$.

Итого имеем, что $A \rightarrow \alpha_1 \dots \alpha_n$, $\alpha_m \vdash w_m$, $w_1 \dots w_n = w$. Из всего этого следует, что $A \vdash w_1 \dots w_n = w$. Переход доказан.

Из доказанной леммы следует, что:

$$\begin{aligned} w \in L(G) &\iff S \vdash w \iff \langle q_1, w, S \rangle \vdash \langle q_1, w, S \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle \text{ (по лемме)} \\ w \in L(M) &\iff \langle q_0, w, \varepsilon \rangle \vdash_1 \langle q_1, w, S \rangle \vdash \langle q_1, \varepsilon, \varepsilon \rangle \end{aligned}$$

■

18. Совпадение классов КС-языков и языков, распознаваемых МП-автоматами: построение грамматики по автомату.

Automaton \Rightarrow Gram


▲ Пусть $w \in L(M)$, M — МП-автомат, для которого выполнено соотношение:

$$\forall (\langle q_1, u, \alpha \rangle \rightarrow \langle q_2, \beta \rangle) \in \Delta : |u| \leq 1, |\alpha| + |\beta| = 1$$

Для вывода построим график «длина стека» от префикса w :

$$\langle q_0, w, \varepsilon \rangle \vdash \langle q, u, \gamma \rangle$$


На графике — точка $(|\gamma|, |w| - |u|)$.



Далее зададим грамматику $G = \langle N, \Sigma, P, S \rangle$, где:

$N = S \cup \{A_{ij} | q_i, q_j \in Q\}$ Под A_{ij} подразумевается то, что выводится на пути между q_i и q_j без изменения стека (нет pop()). P — объединение следующих множеств:

1. $\{A_{ii} \rightarrow \varepsilon | q_i \in Q\}$
2. $\{S \rightarrow A_{0j} | q_j \in F\}$
3. $\{A_{ij} \rightarrow aA_{rs}bA_{tj} | \alpha \wedge \beta\}$, где:
 - (a) α : условие, что $\langle q_i, a, \varepsilon \rangle \rightarrow \langle q_r, A \rangle \in \Delta$;
 - (b) β : условие, что $\langle q_s, b, A \rangle \rightarrow \langle q_t, \varepsilon \rangle \in \Delta$.



Теперь нужно доказать следующую лемму:

Лемма: $A_{ij} \vdash_G w \iff \langle q_i, w, \varepsilon \rangle \vdash_M \langle q_j, \varepsilon, \varepsilon \rangle$

\implies Докажем индукцией по длине вывода в грамматике.

База. Вывод за один шаг. $A_{ij} \rightarrow \varepsilon$. Тогда $i = j$, $w = \varepsilon$, $\langle q_i, \varepsilon, \varepsilon \rangle \vdash \langle q_i, \varepsilon, \varepsilon \rangle$.

Переход. Пусть $A_{ij} \vdash w$ за k шагов. Тогда $A_{ij} \vdash aA_{rs}bA_{tj}$, при этом:

$$\langle q_i, a, \varepsilon \rangle \rightarrow \langle a_r, A \rangle \quad (1)$$

$$\langle q_s, b, A \rangle \rightarrow \langle q_t, \varepsilon \rangle \quad (3)$$

Слово w имеет вид $aubv$. Тогда, используя предположение индукции, можем получить:

$$A_{rs} \vdash u \implies \langle q_r, u, \varepsilon \rangle \stackrel{(2)}{\vdash} \langle q_s, \varepsilon, \varepsilon \rangle$$

$$A_{tj} \vdash v \implies \langle q_t, v, \varepsilon \rangle \stackrel{(4)}{\vdash} \langle q_j, \varepsilon, \varepsilon \rangle$$

$$\text{Тогда } \langle q_i, aubv, \varepsilon \rangle \stackrel{(1)}{\vdash} \langle q_r, ubv, A \rangle \stackrel{(2)}{\vdash} \langle q_s, bv, A \rangle \stackrel{(3)}{\vdash} \langle q_t, v, \varepsilon \rangle \stackrel{(4)}{\vdash} \langle q_j, \varepsilon, \varepsilon \rangle.$$

\Leftarrow Проведём индукцию по количеству переходов k , которые необходимы для того, чтобы $\langle q_i, w, \varepsilon \rangle \vdash \langle q_j, \varepsilon, \varepsilon \rangle$.

База. $k = 0$. Тогда $\langle q_i, w, \varepsilon \rangle \vdash_0 \langle q_j, \varepsilon, \varepsilon \rangle$, откуда $w = \varepsilon$ и $q_i = q_j$, $A_{ij} = A_{ii}$, так как есть правило $A_{ii} \rightarrow \varepsilon$, то $A_{ii} \vdash \varepsilon$.

Переход. $\langle q_i, w, \varepsilon \rangle \vdash_k \langle q_j, \varepsilon, \varepsilon \rangle$. Так как стек пустой, то:

$$\langle q_i, w, \varepsilon \rangle \vdash_1 \langle q_r, u, A \rangle$$

A существует, так как мы либо кладём, либо снимаем со стека. Пусть $q_s \rightarrow q_t$ — это момент, когда A снят со стека. Тогда:

$$\begin{aligned} \langle q_s, v, A \rangle \vdash_1 \langle q_t, x, \varepsilon \rangle \vdash \langle q_j, \varepsilon, \varepsilon \rangle \\ \langle q_i, a, \varepsilon \rangle \rightarrow \langle q_r, A \rangle \in \Delta : w = au \\ \exists u' : u = u'v, \langle q_r, u', \varepsilon \rangle \vdash \langle q_s, \varepsilon, \varepsilon \rangle \end{aligned}$$

Пользуясь предположением индукции, получаем:

$$\begin{aligned} A_{rs} \vdash u' \\ \langle q_s, b, A \rangle \vdash \langle q_t, \varepsilon \rangle \in \Delta : v = bx \\ \langle q_t, x, \varepsilon \rangle \vdash \langle q_j, \varepsilon, \varepsilon \rangle \implies A_{tj} \vdash x \end{aligned}$$

Так как правило $A_{ij} \rightarrow aA_{rs}bA_{tj} \in P$, то $A_{ij} \vdash aA_{rs}bA_{tj} \vdash au'bx = au'v = au = w$. Предположение доказано.

Из леммы будет следовать теорема следующим образом:

$$\begin{aligned} w \in L(G) &\iff S \vdash w \iff \exists A_{0j} (q_j \in F) : S \vdash_1 A_{0j} \vdash w \iff (\text{по лемме}) \\ &\iff \exists A_{0j} (q_j \in F) : \langle q_0, w, \varepsilon \rangle \vdash \langle q_j, \varepsilon, \varepsilon \rangle \iff \exists q_j \in F : \langle q_0, w, \varepsilon \rangle \vdash \langle q_j, \varepsilon, \varepsilon \rangle \iff w \in L(M) \end{aligned}$$

□

19. Нормальная форма Грейбах для КС-грамматик. Модифицированный алгоритм Кока-Янгера-Касами для нормальной формы Грейбах: достоинства и недостатки.

Определение: Грамматика в нормальной форме Грейбах (grammar in Greibach normal form) — контекстно-свободная грамматика $\langle N, \Sigma, P, S \rangle$, в которой каждое правило имеет один из следующих четырёх видов:

- 1) $S \rightarrow \varepsilon$
- 2) $A \rightarrow a$
- 3) $A \rightarrow aB$
- 4) $A \rightarrow aBC$

причём $B, C \in N$, $B, C \neq S$, $a \in \Sigma$

Модифицированный алгоритм Кока-Янгера-Касами

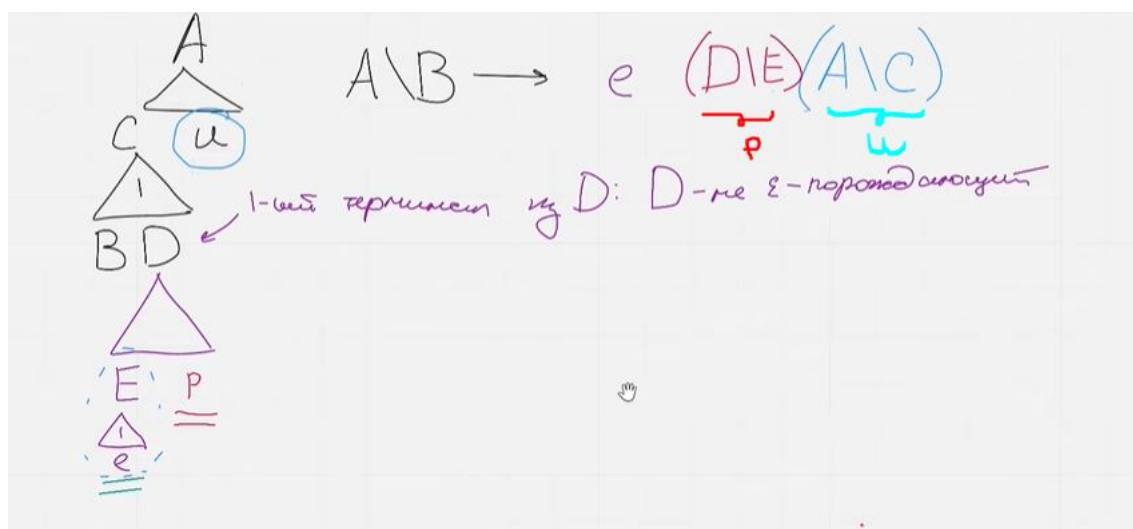
Утверждение: проще парсить из нормальной формы Грейбаха, т.к. каждый раз мы вытаскиваем одну букву \Rightarrow в алгоритме Кока-Янгера-Касами константа будет ниже;

Минус: большое количество нетерминалов.

Теорема Каждая контекстно-свободная грамматика эквивалентна некоторой грамматике в нормальной форме Грейбах. (на хор 6 и выше по версии Виталия)

▲ 0. Возьмём G в НФ Хомского. Введём обозначение: $A \setminus B \vdash w \Leftrightarrow A \vdash Bw$

1. Заметим следующее:



2. Вводим $G' = \langle N', \Sigma, P', S \rangle$, где $N' = \{S\} \cup \{(A \setminus B) \mid A, B \in N\}$,

а $P' = \{(A \setminus A) \rightarrow \varepsilon \mid A \in N\} \cup \{S \rightarrow a(S \setminus A) \mid A \rightarrow a \in P\} \cup \{(A \setminus B) \rightarrow \epsilon(D \setminus E)(A \setminus C) \mid C \rightarrow BD, E \rightarrow e \in P\} \cup \{S \rightarrow \varepsilon \mid S \rightarrow \varepsilon \in P\}$. Отсюда $O(N') = O(N^2)$ ■

Осталось доказать: $\forall A, B \in N \forall w \in \Sigma^* A \vdash_G Bw \Leftrightarrow (A \setminus B) \vdash_{G'} w$

\Rightarrow : индукция по длине вывода в G . База: $A = B$, $w = \varepsilon$. Переход: см. картинку

\Leftarrow : индукция по длине вывода в G' . База: $A \setminus B \vdash_1 w \Rightarrow w = \varepsilon, A = B \Rightarrow A \vdash A\varepsilon$.

Переход: $A \setminus B \vdash_1 e(C \setminus D)(A \setminus F); (C \setminus D) \vdash u$; по предположению индукции, $C \vdash Du$. Аналогично, $A \vdash Fv$. + в P есть правила $D \rightarrow e$ и $F \rightarrow BC$.

Тогда $A \vdash Fv \vdash BCv \vdash BDuv \vdash Beuv$. Почти победа!

$\mathbf{L}(G) = \mathbf{L}(G')$. $w \in L(G) \Leftrightarrow S \vdash w$.

$L(G) \subset L(G')$: пусть $S \vdash w$

1) $w = \varepsilon$, переносим правило $S \rightarrow \varepsilon$ в G'

2) $w \neq \varepsilon$. Тогда $w = au$. $S \vdash Au \vdash_1 au$, т.к. НФ Хомского. По лемме $S \setminus A \vdash u \Rightarrow S \vdash_{G'} a(S \setminus A) \vdash au = w$.

$L(G') \subset L(G)$: $w = au$, $S \vdash_{G'} a(S \setminus A)$, где $A \rightarrow a \in P$, тогда $S \setminus A \vdash u$, в итоге $S \vdash Au = au = w$.

20. Линейные и полулинейные множества. Лемма о том, что для всякого полулинейного множества есть регулярный язык. Теорема Парика: существование КС-языка для полулинейного множества.

$$w \in L : L \subset \Sigma^*; \Sigma = \{a_1, a_2, \dots, a_n\} \Rightarrow \exists \psi : \forall w \rightarrow (|w|_{a_1}, |w|_{a_2}, \dots, |w|_{a_n})$$

Если L - регулярный язык, то $\psi(L)$ - ?

Введём операции: сложение - $X + Y = \{x + y | x \in X, y \in Y\}$, выпуклая оболочка: $\langle X \rangle = \{\alpha_1 x_1 + \dots + \alpha_n x_n | x_1, \dots, x_n \in X, \alpha_1, \dots, \alpha_n \in \mathbb{Z}^+, \alpha_i \geq 0\}$

$X \subseteq \mathbb{N}^k$, $X = X_1 + \langle X_2 \rangle$, $|X_1|, |X_2| < \infty$ - **линейное**

Примеры:

$\psi(abaab) = (3, 2)$; $\psi((ab)^*) = \{(n, n) | n \geq 0\}$, $\psi((ab)^*) = \langle (1, 1) \rangle$, $\psi((ab)^*) = (0, 0) + \langle (1, 1) \rangle$
(первая компонента - базовое положение, вторая - разрастание, т.е. идейно это похоже на лемму о разрастании)

$X \subseteq \mathbb{N}^k$ - **полулинейное**, если X представимо в виде конечного объединения линейных множеств.

Соответственно, язык L - (полу)линейный, если $\psi(L)$ - (полу)линейный.

Утверждение: L - регулярный $\Rightarrow L$ - полулинейный.

Лемма: $\forall X \subseteq \mathbb{N}^{|\Sigma|}$ полулинейного $\exists R$ (полулинейный) - регулярный язык ($\psi(R) = X$)

Теорема Па'рика: L - КС язык $\Rightarrow L$ - полулинейный.

Док-во леммы:

X - полулинейное. Надо найти $R : \psi(R) = X$

$X = X_1 \cup \dots \cup X_l$, X_i - линейное. Для X_i найдём $R_i : \psi(R_i) = X_i$; $X_i = \{x_1, \dots, x_m\} + \langle \{y_1, \dots, y_t\} \rangle$, $x_i, y_i \in \mathbb{N}^{|\Sigma|} : x_j \rightarrow u_j : \psi(u_j) = x_j = \{x_j^1, \dots, x_j^{|\Sigma|}\}$

$$\begin{aligned}
 x_j &\rightarrow u_j : \psi(u_j) = x_j = \{x_j^1, \dots, x_j^{|\Sigma|}\} \\
 u_j &= a_1^{x_j^1} \cdot a_2^{x_j^2} \cdot \dots \cdot a_{|\Sigma|}^{x_j^{|\Sigma|}} \\
 y_i &\rightarrow v_j : v_j = a_1^{y_j^1} \cdot \dots \cdot a_{|\Sigma|}^{y_j^{|\Sigma|}} \\
 \psi((u_1 + u_2 + \dots + u_m)) &= \{x_1, \dots, x_m\} \\
 \psi((u_1 + u_2 + \dots + u_m)(v_1 + \dots + v_t)) &= x_j
 \end{aligned}$$

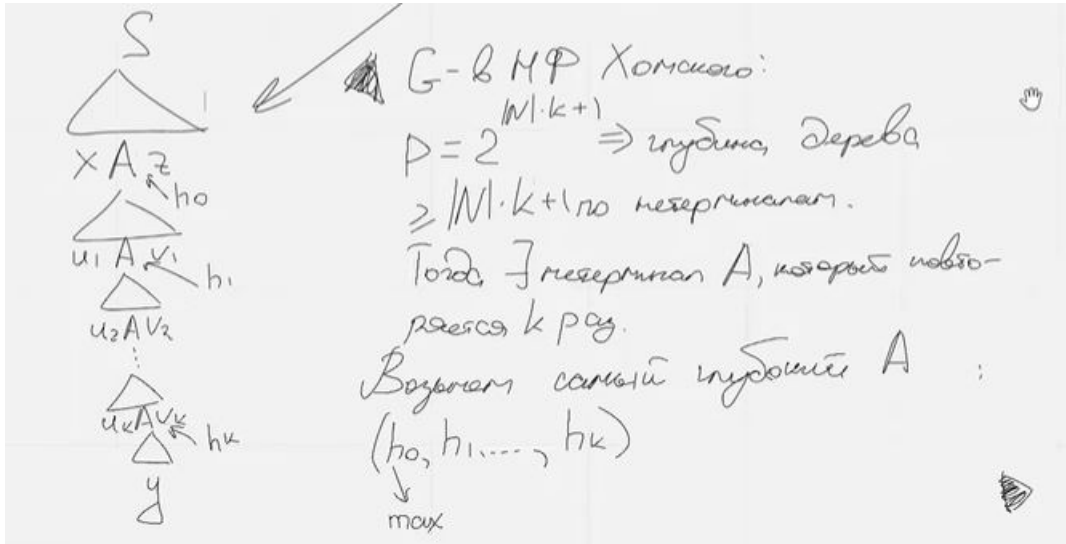
Нашли для X_i , а дальше просто объединение - вот и получили.

21. Линейные и полулинейные множества. Теорема Парика: полулинейность КС-языков.

Лемма: $\forall X \subseteq \mathbb{N}^{|\Sigma|}$ полулинейного $\exists R$ (полулинейный) - регулярный язык ($\psi(R) = X$)

Теорема Па'рика: L - КС язык $\Rightarrow L$ - полулинейный.

Введём лемму о разрастании: G - КС язык. Тогда: $\forall k \exists p : \forall w \in L : |w| \geq p \exists w = xu_1 \dots u_k y v_k \dots v_2 v_1 z : |u_i v_i| > 0, |u_1 \dots u_k y v_k \dots v_1| \leq p$



▲ G - в НФ Хомского, $p = 2^{|N|k+1} \Rightarrow$ глубина дерева $\geq |N|k + 1$ по нетерминалам. Тогда \exists нетерминал A , который повторяется k раз. Возьмём самый глубокий A : (h_0, h_1, \dots, h_k) ■

Док-во теоремы Парика:


▲ $L = L(G)$: G - в НФ Хомского, $= \langle N, \Sigma, P, S \rangle$. $\forall M \subset N : L_M(G) = \{w | S \vdash w \text{ при помощи только нетерминалов из } M, \text{ причём всех } \}$.

Надо доказать, что $L_M(G)$ - полулинейно (тогда $L(G)$ - объединение конечного числа полулинейных множеств и как следствие полулинейно). Возьмём p из леммы о разрастании, $k = |N|$. $X = \{\psi(w) | w \in L_M(G), |w| \leq p\}$, $Y = \{\psi(uv) | |uv| \leq p \&\& \exists B \vdash uBv \text{ из нетерминалов } M\}$

Лемма: $\psi(L_M(G)) = X + \langle Y \rangle$.

\Leftarrow : $x \in X + \langle Y \rangle$. $x = x_1 + \alpha_1 y_1 + \dots + \alpha_m y_m$; $x_1 \in X \Rightarrow \exists w' : w' \in L_M(G), |w'| \leq p$.

$y_i \in Y \Rightarrow \exists w_i = u_i v_i$: вывод $B_i \vdash u_i B_i v_i$ из M . Финт ушами: $w' \in L_M(G) \Rightarrow \exists$ вывод со всеми нетерминалами B : рисуем ёлку вида



w'' - слово после "подвешивания" $B_i \vdash u_i B_i v_i$ к дереву вывода; $w'' \in (L_M(G) : \psi(w'') = x$


Победа!

$\Rightarrow: w \in L_M(G) \Rightarrow \psi(w) \in X + \langle Y \rangle$.

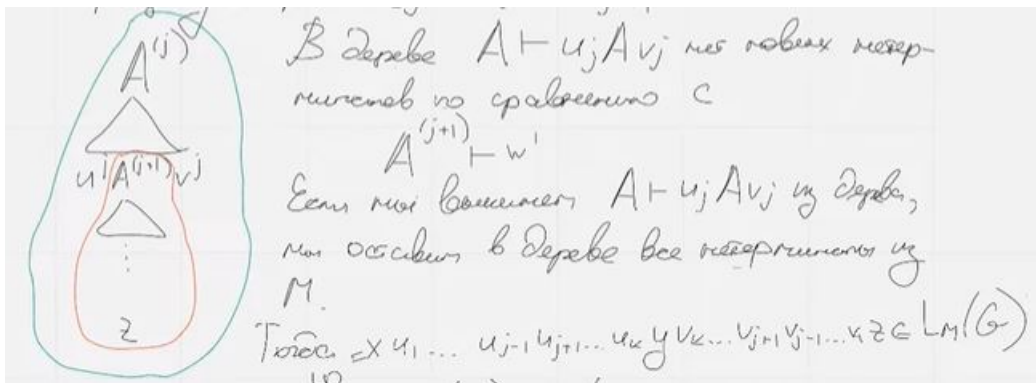
Индукция по длине слова.

База: $|w| \leq p \Rightarrow \psi(w) \in X$.

Переход: для $k = |N|$ лемма о разрастании:



M_i - множество нетерминалов, не считая A, которые встречаются в выводе: $A^{(i)} \vdash u_{i+1}u_{i+2} \dots u_k y v_k \dots$.
Тогда $|M| > |M_0| \geq |M_1| \geq |M_2| \geq \dots \geq |M_k| \geq 0$; $k+1$ число = $|N| + 1$ число от 0 до $|M| - 1$.
Тогда по принципу Дирихле $\exists j : M_j = M_{j+1}$.



$\psi(w) = \psi(w) + \psi(u_j v_j)$, $\psi(w) \in X + \langle Y \rangle$, $\psi(u_j v_j) \in Y$ (первое по предположению индукции).
Ура!

■

3. Парсеры

Основная информация об алгоритме Эрли

Пусть $w \in \Sigma^*$ — слово на входе. На вход подаётся контекстно-свободная грамматика $G = \langle N, \Sigma, P, S \rangle$.

Определение: Ситуация — объект вида $(A \rightarrow \alpha \cdot \beta, i)$, где правило $(A \rightarrow \alpha\beta) \in P$, \cdot — вспомогательный символ, который не принадлежит ни Σ , ни N , $i \in [0; |w|]$.

Определение: D_j — множество ситуаций вида $(A \rightarrow \alpha \cdot \beta, i)$ таких, что $\alpha \vdash w[i : j]$.

Замечание: Вывод считаем левосторонним: пусть правило $(A \rightarrow \beta) \in P$, тогда:

$$S \vdash \varphi A \psi \vdash_1 \varphi \beta \psi \implies \varphi \in \Sigma^*$$

Замечание: Ситуация $(A \rightarrow \alpha \cdot \beta, i) \in D_j$ означает, что:

1. $S \vdash w[0 : i]$, где S — стартовый нетерминальный символ;
2. $(A \rightarrow \alpha\beta) \in P$;
3. $\alpha \vdash w[i : j]$.

Если вдруг с алгоритмом Эрли вы встречаетесь впервые, то представьте, что точка играет роль курсора, слева от которого то, что уже было введено, а справа находится то, что предстоит обработать.

Замечание: Для удобства вводится новый стартовый нетерминальный символ S' , а также в грамматику G добавляется правило $(S' \rightarrow S)$. На выводимость слова это не влияет.

Операции

Всего в алгоритме Эрли поддерживаются три операции: **Scan**, **Predict**, **Complete**. Проще говоря, *Scan* отвечает за «прочтение» нового символа слова, то есть появляются ситуации, которые соответствуют тому, как префикс слова мог быть выведен, *Predict* отвечает за генерацию возможных ситуаций при прочтении следующего символа, который является нетерминальным, то есть как бы «предсказывает», по каким правилам слово может быть выведено дальше, *Complete* отвечает как бы за проверку того, было ли правильным «предсказание» со стороны операции *Predict*. Теперь переходим к формальным определениям операций:

$$\begin{aligned} \text{Scan: } & \begin{cases} (A \rightarrow \alpha \cdot a\beta, i) \in D_j \\ w[j] = a \end{cases} \implies (A \rightarrow \alpha a \cdot \beta, i) \in D_{j+1} \\ \text{Predict: } & \begin{cases} (A \rightarrow \alpha \cdot B\beta, i) \in D_j \\ (B \rightarrow \gamma) \in P \end{cases} \implies (B \rightarrow \cdot \gamma, j) \in D_j \\ \text{Complete: } & \begin{cases} (B \rightarrow \gamma \cdot, k) \in D_j \\ (A \rightarrow \alpha \cdot B\beta, i) \in D_k \end{cases} \implies (A \rightarrow \alpha B \cdot \beta, i) \in D_j \end{aligned}$$

Инициализация: $(S' \rightarrow \cdot S, 0) \in D_0$. Слово выводимо в грамматике G тогда и только тогда, когда ситуация $(S' \rightarrow S \cdot, 0) \in D_{|w|}$.

Remind.

Ситуация - объект вида $(A \rightarrow \alpha \cdot \beta, i)$.

$$(A \rightarrow \alpha \cdot \beta, i) \in D_j \iff S \vdash_l w_{0i} A \gamma, A \rightarrow \alpha \beta \in P, \alpha \vdash_l w_{ij}$$

Note: \vdash_l - выводится левосторонним образом

Note: $w_{ij} = w[i, j)$

Remind.

$$w \in L(G) \iff (S' \rightarrow S \cdot, 0) \in D_{|w|}$$

Remind.

$$\text{Predict: } \forall B \rightarrow \gamma \in P \quad \frac{(A \rightarrow \alpha \cdot B \beta, i) \in D_j}{(B \rightarrow \cdot \gamma, j) \in D_j}$$

$$\text{Scan: } \forall a \in \Sigma : w[j] = a \quad \frac{(A \rightarrow \alpha \cdot a \beta, i) \in D_j}{(A \rightarrow \alpha a \cdot \beta, i) \in D_{j+1}}$$

$$\text{Complete: } \frac{(A \rightarrow \alpha \cdot B \gamma, i) \in D_k \quad (B \rightarrow \beta \cdot, k) \in D_j}{(A \rightarrow \alpha B \cdot \gamma, i) \in D_j}$$

Алгоритм Эрли

```
def earley(word, grammar):
    D0 = {S' → ·S, 0}
    while D0 changes:
        D0 = Complete(D0)
        D0 = Predict(D0)

    for i in range(1, |w|):
        Di = Scan(Di-1, wi)
        while Di changes:
            Di = Complete(Di)
            Di = Predict(Di)

    return {S' → S·, 0} in D|w|
```

22. Алгоритм Эрли синтаксического разбора для КС-грамматик: доказательство корректности.

Нужно доказать, что алгоритм правильно строит множества $D_0, \dots, D_{|w|}$. Это равносильно тому, что он поддерживает инвариант вида $(A \rightarrow \alpha \cdot \beta, i) \in D_j \Leftrightarrow \exists \delta \in (\Sigma \cup N)^* ((S \vdash w_{0i} A \delta) \wedge \alpha \vdash w_{ij})$.

▲ \Rightarrow . Индукция по построению множеств D_j . $(A \rightarrow \alpha \cdot \beta, i)$ попадает в D_j в результате некоторой операции: база - $(S \rightarrow S', 0)$ удовлетворяет инварианту;

Если операция **Scan**, то $\alpha = \alpha' a$, $a = w[j-1]$ и $(A \rightarrow \alpha' \cdot a \beta, i) \in D_{j-1}$. По индукции $S \vdash w_{0i} A \delta$, а значит $\alpha' \vdash w_{i(j-1)}$. Тогда из равенства $a = w[j-1]$ следует $\alpha = \alpha' a \vdash w_{i(j-1)} w[j-1] = w_{ij}$. Чтд.

Если операция **Predict**, то $\alpha = \varepsilon$, $i = j$ - отсюда второй пункт утверждения. Также $\exists i' \leq i$ и ситуация $(A' \rightarrow \alpha' A \delta', i') \in D_{i'}$, откуда по индукции $S \vdash w_{0i'} A' \delta''$, $\alpha' \vdash w_{i'i}$. Получаем $S \vdash w_{0i'} A' \delta'' \vdash w_{0i'} \alpha' A \delta' \delta'' \vdash w_{0i'} w_{i'i} A \delta' \delta'' = w_{0i} A \delta$. Чтд.

Если операция **Complete**, то $\alpha = \alpha' A'$ и $\exists i', \delta : (A \rightarrow \alpha' \cdot A' \beta, i) \in D_{i'}$, $(A' \rightarrow \gamma \cdot, i') \in D_j$. Отсюда $\alpha = \alpha' A' \vdash w_{i'i'} w_{i'j} = w_{ij}$; $S \vdash w_{0i} A \delta$ по предположению индукции. Чтд.

\Leftarrow . Доказательство индукцией по суммарной длине $w_{0i} A \delta$ из S и w_{ij} из α .

Разбираем случаи в зависимости от α . Если $\alpha = \alpha' a$, то $a = w[j-1]$, $\alpha' \vdash w_{i(j-1)}$. По предположению индукции $(A \rightarrow \alpha' \cdot \beta, i) \in D_{j-1}$. Тогда по правилу *Scan* получаем $(A \rightarrow \alpha' \cdot \beta, i) \in D_j$

Если $\alpha = \alpha' B$, тогда получаем, что существует i' , такой что $\alpha' \vdash w_{i'i'}$, $B \vdash w_{i'j}$. Тогда имеем $(A \rightarrow \alpha' \cdot B \beta) \in D_{i'}$. Кроме того, можно записать $S \vdash w_{0i} A \delta \vdash w_{0i} w_{i'i'} B \beta \delta$, а также $B \vdash_1 \gamma \vdash w_{i'j}$. Применяя индукцию по второму параметру, имеем $(B \rightarrow \gamma \cdot, i') \in D_j$, откуда по правилу *Complete* получаем $(A \rightarrow \alpha' B \cdot \beta) \in D_j$, что и требовалось.

Пусть теперь $\alpha = \varepsilon$, тогда $i = j$. Тогда либо $i = 0$, $A = S_1$, $\delta = \varepsilon$, что доказывает базу индукции, либо вывод можно переписать в виде $S \vdash w_{0i'} A' \delta'' \vdash_1 w_{0i'} w_{i'i} A \delta' \delta'' = w_{0i} A \delta$ для некоторого правила $(A' \rightarrow w_{i'i} A \delta') \in P$. Отсюда по предположению индукции следует, что $(A' \rightarrow \cdot w_{i'i} A \delta', i') \in D_{i'}$, что после нескольких применений правила *Scan* приводит к $(A' \rightarrow w_{i'i} \cdot A \delta', i') \in D_i$, после чего по правилу *Predict* мы получаем $(A \rightarrow \cdot \beta, i) \in D_i$, что и требовалось. Корректность доказана. ■

23. Алгоритм Эрли синтаксического разбора для КС-грамматик: доказательство полноты.

Утверждение: Алгоритм Эрли является полным.

▲ Рассмотрим слово w . Если слово w выводимо в грамматике $G = \langle N, \Sigma, P, S \rangle$, то верно, что $S \vdash w$. Пусть $i = 0$, $j = |w|$. Тогда существуют $\varphi, \psi \in (N \cup \Sigma)^*$, что $\varphi \vdash w[0 : 0] = \varepsilon$, $S \vdash w[0 : |w|] = w$, что $S' \vdash \varphi S' \psi \vdash S' \psi \vdash_1 S \psi$. Укажем явно φ и ψ : $\varphi = \varepsilon$, $\psi = \varepsilon$, тогда выполняется, что:

$$S' \vdash_1 S \vdash w$$

По сути, только что расписали подробно $S' \vdash w$. A соответствует нетерминальному символу S' (вспомогательному стартовому нетерминалу), α соответствует нетерминальному символу S , из которого выводится слово w , β соответствует пустому слову ε . По основной лемме об инварианте, доказанной ранее, ситуация $(S' \rightarrow S \cdot, 0) \in D_{|w|}$ тогда и только тогда, когда $S' \vdash w$. Так как из основной леммы следует корректность алгоритма Эрли, то все возможные ситуации будут рассмотрены, и если слово w выводимо в грамматике G , то это эквивалентно тому, что будет рассмотрена ситуация $(S' \rightarrow S \cdot, 0) \in D_{|w|}$, и будет выведено, что $w \in L(G)$. Если слово w не является выводимым в грамматике G , то ситуация $(S' \rightarrow S \cdot, 0) \notin D_{|w|}$, и будет выведено, что $w \notin L(G)$. Значит, алгоритм Эрли является полным. ■

24. Алгоритм Эрли синтаксического разбора для КС-грамматик: обоснование сложности. Примеры случаев, где Эрли ведёт себя квадратично. Как реализовать алгоритм Эрли, чтобы он был эффективным

Эффективное хранение ситуаций и правил

Требуется эффективным образом хранить ситуации типа $\{A \rightarrow \alpha \cdot X\beta, i\} \in D_j$. Множества D_j можно хранить в массиве $D[j][X]$, где $D[j][X] = \{(A_1 \rightarrow \alpha_1 \cdot X\beta_1, i_1), (A_2 \rightarrow \alpha_2 \cdot X\beta_2, i_2), \dots\}$. Возможны три случая, связанные с символом X :

1. $X = a, a \in \Sigma$
2. $X = B, B \in N$
3. $X = \$, \$$ — конец слова

Правила будем хранить в массиве $G[A]$, где в $G[A]$ будут храниться все правила начинающиеся с A , то есть правила вида $A \rightarrow \beta$.

Об операциях

Пусть w — слово.

1. Scan. $\forall j < |w| : w[j] = a$. Тогда нужно рассмотреть все элементы $D[j][a]$ и расположить их в $D[j+1]$ в соответствии с символом, следующим за a . Асимптотика этой операции соответствует $\mathcal{O}(D[j][a])$, то есть она растёт в соответствии с количеством элементов, находящихся в $D[j][a]$.
2. Predict. $\forall j, B$: Пусть ситуация имеет вид $(A \rightarrow \alpha \cdot B\beta, i) \in D_j$. Она лежит в $D[j][B]$. Нужно рассмотреть все правила вида $B \rightarrow \gamma \in P$, они лежат в $G[B]$. Асимптотика этой операции $\mathcal{O}(D[j][B] \cdot G[B])$.
3. Complete. $\forall j, B$: Пусть ситуация имеет вид $(B \rightarrow \gamma \cdot, i) \in D_j$, она лежит в $D[j][\$]$. Нужно рассмотреть все ситуации вида $(A \rightarrow \alpha \cdot B\beta, k) \in D_i$, они лежат в $D[i][B]$. Асимптотика этой операции $\mathcal{O}(\sum_{i \leq j} G[B] \cdot D[i][B])$.

Оценки

Оценим, как растёт величина $|D_j|$. $D_j = \{(A_1 \rightarrow \alpha_1 \cdot \beta_1, i_1), (A_2 \rightarrow \alpha_2 \cdot \beta_2, i_2), \dots\}$. Пусть $|G|$ — сумма всех длин правых частей правил. Значение i может быть от 0 до j , а точка может быть расположена в $\mathcal{O}(|G|)$ мест, поэтому $\mathcal{O}(|D_j|) = (j+1)|G|$.

Асимптотика операции Scan соответствует $\mathcal{O}(|D_j|) = \mathcal{O}(|w| \cdot |G|)$.

Асимптотика всех операций Scan $\mathcal{O}(|D_j| \cdot |w|) = \mathcal{O}(|w|^2 \cdot |G|)$.

Для оценки асимптотики операции Predict рассмотрим множества вида:

$$\begin{aligned} (A \rightarrow \alpha \cdot B\beta, i) &\in D_j \\ (B \rightarrow \cdot \gamma, j) &\in D_j \end{aligned}$$

Так как операция Predict сводится к перебору по i , точке и правилам левая часть которых B , то асимптотика операции соответствует $\mathcal{O}(D[j][B] \cdot G[B]) = \mathcal{O}(|w| \cdot |G| \cdot G[B])$.

Асимптотика всех операций Predict $\mathcal{O}(\sum_{j,B} D[j][B] \cdot G[B]) = \mathcal{O}(|P| \cdot |G| \cdot |w|^2)$, где P - множество всех правил.

Рассмотрим теперь операцию Complete. Ситуации из $D[j][\$]$ указывают на номер множества i и нетерминальный символ B , который соответствует левой части правила из ситуации. Поэтому для каждой ситуации из $D[j][\$]$ будут рассмотрены все ситуации из $D[i][B]$. Поэтому асимптотика всех операций Complete равна $\mathcal{O}(\sum_{j,i \leq j,B} G[B] \cdot D[i][B]) = \mathcal{O}(\sum_{j,i \leq j,B} G[B] \cdot D_i) = \mathcal{O}(\sum_{j,i \leq j} |P| \cdot D_i) = \mathcal{O}(|P| \cdot |w|^2 \cdot |w| \cdot |G|) = \mathcal{O}(|w|^3 |G|^2)$.

Так как итераций $\mathcal{O}(|w|)$, то итоговая сложность алгоритма составляет $\mathcal{O}(|w|^3 |G|^2)$. Однако данную оценку можно сильно улучшить, если грамматически удастся доказать (на лекции не стали доказывать), что количество появлений каждого правила ограничена сверху некоторой константой C , то асимптотика уже будет равна $\mathcal{O}(|w|^2 \cdot C)$. Считаем $|P|, |G|, C$, константами, потому что "вся эта история происходит на стадии компиляции". (в алгоритме мы работаем с одним набором правил, видимо поэтому эти величины можно считать константой)

Есть теорема, что если грамматика однозначна, то алгоритм Эрли для неё стоит квадрат. Идея доказательства в том, что если грамматика однозначна, то в complete в $(A \rightarrow \alpha \cdot B\beta, k) \in D_i, (B \rightarrow \cdot \gamma, i) \in D_j$ не нужно будет перебирать i . Оно будет подбираться однозначно.

Алгоритм за куб.

Инициализация:

$D_0 \leftarrow \{(S \rightarrow \cdot S_1, 0)\}$

for $i = 1, \dots, |w|$ **do**

$D_i \leftarrow \emptyset$;

end

Шаг работы:

for $j = 0, \dots, |w|$ **do**

$Scan(D, j)$;

while D_j *изменяется* **do**

$Complete(D, j)$;

$Predict(D, j)$;

end

end

Function $Scan(D, j)$

if $j = 0$ **then**

return

end

for $(A \rightarrow \alpha \cdot a\beta, i) \in D_{j-1}$ **do**

if $a = w[(j-1)]$ **then**

$D_j.add((A \rightarrow \alpha a \cdot \beta, i))$

end

end

end

```

Function Predict( $D, j$ )
|   for  $(A \rightarrow \alpha \cdot B\beta, i) \in D_j$  do
|   |   for  $(B \rightarrow \gamma) \in P$  do
|   |   |    $D_j.add (B \rightarrow \cdot\gamma, j)$ 
|   |   end
|   end
end

Function Complete( $D, j$ )
|   for  $(B \rightarrow \gamma \cdot, i) \in D_j$  do
|   |   for  $(A \rightarrow \alpha \cdot B\beta, k) \in D_i$  do
|   |   |    $D_j.add (A \rightarrow \alpha B \cdot \beta, k)$ 
|   |   end
|   end
end

```

Эффективный алгоритм и примеры случаев, где Эрли ведёт себя квадратично: (из peers.ifmo)

```

function earleyMod( $G, w$ ):
    // Инициализация
     $D_0 = \{[S' \rightarrow \cdot S, 0]\}$ 
    rulesLoop(0)
    for  $j = 1 \dots n$ 
        for  $[A \rightarrow \alpha \cdot a_j\beta, i] \in D_{j-1}$ 
             $D_j \cup = [A \rightarrow \alpha a_j \cdot \beta, i]$  // Первое правило
        rulesLoop(j)

```

```

function rulesLoop( $j$ ):
     $D_j'' = D_j$ 
    while  $D_j'' \neq \emptyset$ 
         $D_j' = D_j''$ 
         $D_j'' = \emptyset$ 
        for  $[B \rightarrow \eta \cdot, i] \in D_j'$  // Цикл (*)
            for  $[A \rightarrow \alpha \cdot B\beta, k] \in D_i$ 
                 $D_j'' \cup = [A \rightarrow \alpha B \cdot \beta, k]$  // Второе правило

        for  $[B \rightarrow \alpha \cdot A\eta, k] \in D_j'$  // Цикл (**)
            for  $\beta : (A \rightarrow \beta) \in P$ 
                 $D_j'' \cup = [A \rightarrow \cdot\beta, j]$  // Третье правило
     $D_j \cup = D_j''$ 

```


Если входная грамматика однозначна, то время выполнения алгоритма Эрли для слова длины n составляет $O(n^2)$.

Доказательство:

▷

Организуем каждый список разбора D_j таким образом, чтобы по любому символу $x \in \Sigma \cup N$, можно было за $O(1)$ получить список тех и только тех ситуаций, содержащихся в D_j , которые имеют вид $[A \rightarrow \alpha \cdot x\beta, j]$.

Время построения D_0 не зависит от входной строки.

Рассмотрим D_j , $j > 0$.

1. При включении ситуаций по правилу (1) необходимо лишь просмотреть предыдущий список и для каждого его элемента выполнить константное число операций.
2. Рассмотрим правило (2). Можно считать, что внутри цикла (*) рассматриваются те и только те ситуации, которые удовлетворяют условию (так как список таких ситуаций можно по нетерминалу получить за $O(1)$ следующим образом: каждый раз, когда мы добавляем ситуацию вида $[A \rightarrow \alpha \cdot B\beta, i]$ в D_j , мы просмотрим в заранее заготовленном массиве для D_j , есть ли в D_j ситуации вида $[B \rightarrow \eta \cdot, j]$. Если да, то добавим $[A \rightarrow \alpha B \cdot \beta, i]$ в D_j). Тогда каждая такая ситуация будет добавлена в список и, исходя из леммы 2, попытка добавления будет единственной. А так как по лемме 1 всего в списке D_j находится $O(j)$ ситуаций, то суммарно за все итерации внешнего цикла while внутри цикла (*) будет рассмотрено $O(j)$ ситуаций.
3. Так как грамматика фиксирована, то при применении правила (3) при рассмотрении любой ситуации количество включаемых ситуаций не превосходит некоторой константы, поэтому для каждой рассмотренной ситуации будет выполнено $O(1)$ операций.

Таким образом, на построение списка D_j будет потрачено $O(j)$ операций. Тогда время работы алгоритма составляет $O(n^2)$.


25. Анализатор перенос-свёртка, недостатки анализатора.

Мотивировка: У нас есть алгоритм Эрли, но он работает долго.

- Scan: $O(|w|^2|G|)$
- Predict: $O(|w|^2|G|^2)$
- Complete: $O(|w|^3|G|^2)$

Чтобы понять алгоритм, рассмотрим грамматику и слово $w = ab$

- $S' \rightarrow S$ (добавляем)
- $S \rightarrow aB$
- $B \rightarrow b$



Храним стек текущих символов и текущую позицию в слове.

- На вершине стека написана правая часть правила - заменяем на левую (reduce)
- Иначе - добавляем символ в стек и читаем символ (shift)

Стоит заметить, что разбираем мы слово справа налево, а вывод в грамматике правосторонний, поэтому мы будем вынуждены поменять порядок правил на обратный для построения дерева разбора

А в чем проблема?

- 1 А как понять, какая правая часть правила находится на стеке?
- 2 А что делать, если нам подходят несколько правил? (стек можно распарсить двумя и более способами)

26. Определение LR-грамматики, примеры LR и не LR-грамматик. Стековая аналогия определения (нет конфликтов). Вопрос на отл: однозначность lr грамматики.

Определение: Грамматика называется LR(k) грамматикой, если LR-k таблица для этой грамматики строится корректно

Определение: Для $\alpha \in (N \cup \Sigma)^*$ определим $\text{First}(\alpha)$ как:

$\text{First}(\alpha) = \{a | \alpha \rightarrow au, u \in \Sigma^*\} \cup \{\$\} I(\alpha \rightarrow \varepsilon)$ $\text{First}(\alpha)$ - первый символ, который может вывестись из α .

Если $\alpha = a\gamma$, то $\text{First}(\alpha) = a$

Если $\alpha = B\gamma$, $B \rightarrow \varepsilon$, то $\text{First}(\alpha) = \text{First}(B) \cup \text{First}(\gamma)$

Определение: Грамматика называется LR(k) грамматикой, если из условий:

1. $S' \rightarrow \cdot \alpha A w \rightarrow \alpha \beta w$
2. $S' \rightarrow \cdot \gamma B x \rightarrow \alpha \beta y$ где γ - префикс α , возможно, несобственный. x - суффикс w
3. $\text{First}_k(w) = \text{First}_k(y)$

Что происходит в теминах алгоритма? На стеке сейчас лежат $\alpha\beta$ и мы смотрим, верно ли, что можно свернуть однозначно? Наличие двух одинаковых выводов говорит, что нет. То есть алгоритм стоит перед некоторой дилеммой. Можно свернуть A (по правилу $A \rightarrow \beta$) или прочесть что-то еще, и свернуть B (по правилу $B \rightarrow \nu_1\beta\nu_2$). В первом случае мы сворачиваем за один шаг, во втором случае - что-то еще сворачиваем, а уже после сворачиваем B.

Что делать в таких ситуациях? А ничего. мы говорим, что такого не допускаем :)

То есть мы говорим, что $\alpha Ay = \gamma Bx$, то есть $\alpha = \gamma, A = B$ **Конец определения**

Примеры LR грамматик

- Грамматика из примера к предыдущему билету
- - $S \rightarrow A$
 - $A \rightarrow aA \mid b$
 - $S \rightarrow A \mid aB$
 - $A \rightarrow aA \mid r$
 - $B \rightarrow aB \mid m$

Эти грамматики парсятся LR(0), и, соответственно, любой другой грамматикой

Любая неоднозначная грамматика - не LR грамматика

$A \rightarrow A + A \mid A - A \mid a$

неоднозначно, поскольку есть два крайних левых вывода для строки $a + a + a$:

$A \rightarrow A + A$ $A \rightarrow A + A$


$\rightarrow a + A$ $\rightarrow A + A + A$ (Первый A заменяется на $A + A$. Замена второго A приведет к аналогичному выводу)

$\rightarrow a + A + A$ $\rightarrow a + A + A$

$\rightarrow a + a + A$ $\rightarrow a + a + A$

$\rightarrow a + a + a$ $\rightarrow a + a + a$

В качестве другого примера грамматика неоднозначна, поскольку существует два **дерева синтаксического анализа** для строка $a + a - a$:



Язык, который она генерирует, однако, не является неоднозначным по своей сути; следующая однозначная грамматика порождает тот же язык:

$A \rightarrow A + a \mid A - a \mid a$

Дополнительно. Пример грамматики LR(1), не являющейся LR(0) грамматикой

- $S' \rightarrow S$
- $S \rightarrow Bb$
- $S \rightarrow Cc$
- $B \rightarrow a$
- $C \rightarrow a$

LR(0) разбор

- 0 $- S' \rightarrow \cdot S$
 $- S \rightarrow \cdot Bb$
 $- S \rightarrow \cdot Cc$
 $- B \rightarrow \cdot a$
 $- C \rightarrow \cdot a$
- 1 $- B \rightarrow a \cdot$
 $- C \rightarrow a \cdot$

И все, есть два reduce. Мы не знаем, что делать. A в терминах вывода это означает, что мы могли открыть букву как ab и как ac , и неважно, что слова разные, у нас уже конфликт в явном виде

LR(1) разбор

- 0 $- S' \rightarrow \cdot S, \$$
 $- S \rightarrow \cdot Bb, \$$


- $S \rightarrow \cdot Cc\$$
- $B \rightarrow \cdot a, b$
- $C \rightarrow \cdot a, c$

- 1 - $B \rightarrow a \cdot, b$
- $C \rightarrow a \cdot, c$

Тут такого противоречия нет, так как мы подсмотрели следующие буквы и поняли, что это соответственно будут reduce(3) и reduce(4), то есть сейчас мы эти ситуации отличаем

Однозначность LR-грамматики (на отл):

2 Пусть α неоднозначна, т.е. это слово Σ^* с двумя различными правостор. выводами. Рассмотрим последний момент, когда концы выводов совпадают, т.е. в обратном правост. выводе мы по-разному свернули подстроку текущей цепочки, а именно:



$$S' \vdash \alpha \beta A \xi \rightarrow \alpha \beta \gamma \delta \xi$$

$$S' \vdash \alpha \beta \gamma \xi \rightarrow \alpha \beta \gamma \delta \xi$$

Обратим внимание, то мы получили стр-ие LR(0)-грам-ки (подстроки выделены для наглядности). Но по определению $A = B$, $\xi = \delta \xi$, $\alpha \beta = \alpha \Rightarrow$ в обоих выводах использовалась правило $A \rightarrow \gamma$ для строки $\alpha A \xi$, хотя по предположению выводы в этом моменте отличаются \Rightarrow грамм-ка неоднозначна

27. Алгоритм построения LR-таблицы. Вопрос на отл: доказательство корректности и полноты. Если верно определение, таблица строится и если не верно, не строится. Критерий LR-овости (отсутствие противоречий).

Определение: $A \rightarrow \alpha \cdot \beta, a_1 \dots a_k$ - LR(k)-ситуация (неформально: если находимся в $A \rightarrow \alpha \cdot \beta$, то $a_1 \dots a_k$ - первые буквы того, что можем вывести дальше, $a_i \in \Sigma \cup \{\$ \}$)

Замечание: Далее будем рассматривать алгоритм LR(1), для $k \neq 1$ действуем аналогично.

Определение: Пусть I - множество ситуаций. Тогда $CLOSURE(I) := J, I \subset J$, такое что

$$\left. \begin{array}{l} B \rightarrow \gamma \in P \\ A \rightarrow \alpha_1 \cdot B\alpha_2, a \in J \end{array} \right\} \Rightarrow \forall c \in First(\alpha_2 a) : B \rightarrow \cdot \gamma, c \in J$$

Определение: Пусть I - множество ситуаций, $\lambda \in \Sigma \cup N$. Тогда

$$GOTO(I, \lambda) := CLOSURE(\{ \langle A \rightarrow \alpha_1 \lambda \cdot \alpha_2 \rangle \mid \langle A \rightarrow \alpha_1 \cdot \lambda \alpha_2 \rangle \in I \})$$

```

item[] closure(item[] I):
    bool changed
    item[] J = I
    repeat
        changed = false
        for [A → α · Bβ, a] ∈ I
            for (B → γ) ∈ Γ'.P
                for b ∈ FIRST(βa)
                    J.add([B → ·γ, b])
                    changed = true
    until not changed
    return J

```

```

item[] goto(item[] I, char X):
    item[] J = ∅
    for [A → α · Xβ, a] ∈ I
        J.add([A → αX · β, a])
    return closure(J)

```

Построим ДКА, вершинами которого будут множества ситуаций, а на ребрах будут написаны символы из $\Sigma \cup N$, по которым будем делать *GOTO*. Как строим: в начальное состояние добавляем $S' \rightarrow \cdot S, \$$. Затем берем *CLOSURE* от состояния, делаем *GOTO* по всем возможным буквам - получаем новые вершины автомата, в которые ведут ребра по этим буквам. Повторяем процесс для добавленных состояний и тд.

```

item[][] items( $\Gamma'$ ):
    bool changed
    item[][] C
    C.add(closure({[ $S' \rightarrow \cdot S, \$$ ]}))
    repeat
        changed = false
        for item[] I  $\subset$  C
            for  $X \in \Gamma'.\Sigma$ 
                if goto(I, X)  $\neq \emptyset$  and goto(I, X)  $\notin$  C
                    C.add(goto(I, X))
                    changed = true
    until not changed
    return C

```

Теперь нам остается только построить таблицу *table* по автомату (столбцы - символы из $N \cup \Sigma \cup \{\$, \}$, строки - номера состояний в автомате):

1. Если из состояния i в состояние j ведет ребро по букве a , то $table[i][a] = (shift, j)$.
2. Если в состоянии i есть ситуация $A \rightarrow \alpha \cdot, a$, то $table[i][a] = (reduce, j)$, где j - номер правила $A \rightarrow \alpha$ в грамматике. Если нужно записать $(reduce, 0)$, то есть свертка по правилу $S' \rightarrow S$, то записываем $table[i][a] = accept$
3. Если никакой из прошлых пунктов не записался, то $table[i][a] = error$

```

// вход:  $\Gamma'$  – расширенная грамматика
// выход: таблица  $T$  канонического LR(1)-анализа
function getLR1CanonicalTable( $\Gamma'$ ):
     $C'(\Gamma') \leftarrow \{I_0, I_1..I_n\}$  // множество канонических ситуаций для  $\Gamma'$ 
    fillArray(T, Error):
        foreach
            if [ $A \rightarrow \alpha \cdot a\beta, b$ ]  $\in I_i$  and goto( $I_i, a$ ) =  $I_j$  // здесь  $a$  – терминал
                 $T[i, a] = shift(j)$ 
            if [ $A \rightarrow \alpha \cdot, a$ ]  $\in I_i$  and  $A \neq S'$ 
                 $T[i, a] = reduce(A \rightarrow \alpha)$ 
            if [ $S' \rightarrow S \cdot, \$$ ]  $\in I_i$ 
                 $T[i, \$] = Accept$ 
            if goto( $I_i, A$ ) =  $I_j$ 
                goto[i, A]  $\leftarrow j$ 

```

28. Алгоритм разбора по LR-таблице. Структура стека. Корректность и полнота разбора (на отл).

Пусть у нас есть готовая LR-таблица $table$ и дано слово $w = w_1 \dots w_n \$$. Создаем стек: изначально записываем в него 0 - номер правила $S' \rightarrow S$, так как оно всегда первое в нашем выводе. Далее запускаем цикл

1. Если последний символ на стеке - это номер правила (i), то пытаемся дописать на стек следующую букву слова w_j : проверяем, если в ячейке $[i, w_j]$ стоит пометка *shift* (то есть из текущего состояния есть переход по этой букве), то дописываем эту букву на стек, иначе говорим, что слово не лежит в языке.
2. Берем последние 2 символа со стека: среди них гарантированно одна буква (c) и одно число (k). Смотрим в ячейку $[k, c]$
 - (a) Если там стоит (*shift, to*), то дописываем на стек to - номер состояния в который надо перейти
 - (b) Если там стоит (*reduce, rule*), то находим правило под номером $rule$, удаляем со стека $2 \cdot |rule.right|$ символов (нужно удалить все буквы из этого правила, но на стеке они чередуются с цифрами, поэтому умножаем длину на 2) и дописать $rule.left$. Если делаем свертку по 0 правилу $S' \rightarrow S$, то есть в этой ячейке стоит *Accept*, то говорим, что слово лежит в языке.
 - (c) Если там стоит *Error*, то слово не лежит в языке

Из алгоритма видно, что на стеке чередуются буквы и числа (в самом начале число)

4. Конечные преобразователи

29. Конечные преобразователи и задаваемые ими преобразования. Различные варианты определения. Примеры конечных преобразований. Теорема Нива.

Определение: Конечный преобразователь $T = \langle Q, \Sigma, \Gamma, \Delta, q_0, F \rangle$:

1. Q — множество состояний, $|Q| < \infty$;
2. Σ — входной алфавит, $|\Sigma| < \infty$;
3. Γ — выходной алфавит, $|\Gamma| < \infty$;
4. $\Delta \subset (Q \times \Sigma^*) \times (Q \times \Gamma^*)$ — множество переходов;
5. $q_0 \in Q$ — стартовое состояние;
6. $F \subset Q$ — множество завершающих состояний. Можно считать, что $|F| = 1$

Определение: Конфигурация КПтеля T — это тройка $\langle q, u, v \rangle$ ($q \in Q, u \in \Sigma^*, v \in \Gamma^*$)

Неформально: находимся в состоянии q ; осталось прочесть слово u ; вывели слово v

Определение: Отношение выводимости (\vdash) — наименьшее рефлексивное транзитивное отношение, что:

$$\forall \langle q_1, u \rangle \rightarrow \langle q_2, v \rangle \in \Delta \text{ выполнено: } \forall y \in \Sigma^*, z \in \Gamma^* : \langle q_1, uy, z \rangle \vdash \langle q_2, y, zv \rangle$$

Определение: Соответствие, задаваемое конечным преобразователем T :

$$\psi = \{(u, v) \in \Sigma^* \times \Gamma^* \mid \exists q \in F : \langle q_0, u, \varepsilon \rangle \vdash \langle q, \varepsilon, v \rangle\}$$

Определение: Конечное преобразование (КП) — это $\psi : \Sigma^* \rightarrow \Gamma^*$


Примеры:

1) $\text{id} \quad (\Gamma = \Sigma) = \text{echo} \rightarrow \bigcirc^{x:x} \quad x \in \Sigma$

2) $\psi : \{ (u, \varepsilon) : u \in R \}$ R — регулярный язык
 $\langle q_1, a \rangle \xrightarrow{M} q_2 \Rightarrow \langle q_1, a \rangle \xrightarrow{T} \langle q_2, \varepsilon \rangle$


Аналогично, $\psi = \{ (\varepsilon, v) : v \in R \}$

3) Конкатенация $\psi_i = \{ (u_i, v_i) \} \quad i=1,2$
 Тогда $\psi = \psi_1 \psi_2 = \{ (u_1 u_2, v_1 v_2) \}$



4) $\psi = \omega \rightarrow \{ \omega u : u \in R \} = \omega R^*$
 Это $\psi = \text{id} \cdot \{ (\epsilon, u) : u \in R \}$

5) $\psi_1 - \text{КП}, \psi_2 - \text{КП} \Rightarrow \psi_1 \cup \psi_2 - \text{КП}$



6) Пусть φ - гомоморфизм: $\Sigma \rightarrow \Gamma$
 т.е. $\varphi(uv) = \varphi(u)\varphi(v)$



Пример: солнечный язык

каша \rightarrow касашаса т.к. $\varphi(ωn) = ωn$; $\varphi(n) = n.c.n$


Определение: Неудлиняющий гомоморфизм – это $\psi : \forall x \in \Sigma^* \quad |\psi(x)| \leq |x|$

Лемма: $\forall T = \langle Q, \Sigma, \Gamma, \Delta, q_0, F \rangle \exists$ эквивалентный ему $T' = \langle Q', \Sigma, \Gamma, \Delta', q_0, F' \rangle$:


$\forall \langle q_1, u \rangle \rightarrow \langle q_2, v \rangle \in \Delta' : |u| + |v| = 1.$

▲ Аналогично НКА.

$u = u_1 u_2 \dots u_k, v = v_1 v_2 \dots v_m$. Добавим состояния и переходы вида $u_i : \epsilon$ и $\epsilon : v_j$.



Осталось убрать переходы вида $\epsilon : \epsilon$ (не забываем корректно проставить завершающие состояния):



■

Теорема Нива: Любое конечное преобразование можно представить в виде композиции:

- обратного неукорачивающего гомоморфизма: $\psi^{-1} : \Theta^* \rightarrow \Sigma^*$
- ограничения на регулярный язык: $id_R \ R \subset \Theta^*$
- неукорачивающего гомоморфизма: $\eta : \Theta^* \rightarrow \Gamma^*$

▲ Если ψ – КП, то существует конечный преобразователь $M : L(M) = \psi$ т.ч. $|u| + |v| = 1$.

Пронумеруем ребра конечного преобразователя $M : e_1, e_2, \dots, e_n$

$$\Theta = \{e_1, e_2, \dots, e_n\}$$

R – все пути из q_0 в F . Заметим, что язык автоматный т.к. на каждом ребре написан символ, ему соответствующий. Поэтому он и регулярный.

ϕ – для каждого ребра берем вход, η – для каждого ребра берем выход

Заметим, что ϕ и η неукорачивающие т.к. $|\phi(x)| \leq 1 \forall x \in \Theta$ т.к. на переходах не более одной буквы.

Докажем теперь про композицию.

$$\psi = (u, v)$$


Рассмотрим автомат над Θ , который мы получаем, когда расписываем все по однобуквенным переходам и нумеруем ребра. В нем есть какой-то путь из q_0 в $q \in F$, пройдя по которому, мы u преобразуем в v , то есть:

$\langle q_0, e_{i1} \dots e_{ik} \rangle \vdash \langle q, \varepsilon \rangle$. Заметим, что тогда $e_{i1}, \dots, e_{ik} \in R$, поэтому id его не изменит (оставит).

$\phi(e_{i1} \dots e_{ik}) = u, \eta(e_{i1} \dots e_{ik}) = v$ (из определения ϕ и η).

Поэтому для $\psi = (u, v) \Rightarrow \exists q \in F : \langle q_0, u, \varepsilon \rangle \vdash_k \langle q, \varepsilon, v \rangle$. ■

Пример:



$$\Theta = e_1, e_2, e_3, e_4, e_5,$$

$$R = (e_1 e_4 + e_2 e_3) e_5^*$$

$$\phi(e_1) = \varepsilon, \phi(e_2) = a, \phi(e_3) = \varepsilon, \phi(e_4) = b, \phi(e_5) = x$$

$$\eta(e_1) = a, \eta(e_2) = \varepsilon, \eta(e_3) = d, \eta(e_4) = \varepsilon, \eta(e_5) = \varepsilon$$

30. Замкнутость конечных преобразований относительно композиции.

Теорема: Если $\psi_1 : \Sigma^* \rightarrow \Gamma^*$ и $\psi_2 : \Gamma^* \rightarrow \Pi^*$ – КП, то $\psi = \psi_2 \circ \psi_1$ – КП

▲ $\psi_1 = L(M_1)$, M_1 – КПТель : $\langle Q, \Sigma, \Gamma, \Delta_Q, q_0, F_Q \rangle$

$\psi_2 = L(M_2)$, M_2 – КПТель : $\langle P, \Gamma, \Pi, \Delta_P, p_0, F_P \rangle$

Тогда $M_{comp} = \langle Q \times P, \Sigma, \Pi, \Delta', (q_0, p_0), (F_Q \times F_P) \rangle$

Сразу отметим, что все переходы в ψ_1, ψ_2 : $|u| + |v| = 1$. Тогда положим:

$$\begin{aligned} \Delta' = & \{ \langle (q_1, p), a \rangle \rightarrow \langle (q_2, p), \varepsilon \rangle \mid \langle q_1, a \rangle \rightarrow \langle q_2, \varepsilon \rangle \in \Delta_Q \} \\ & \cup \{ \langle (q_1, p_1), \varepsilon \rangle \rightarrow \langle (q_2, p_2), \varepsilon \rangle \mid \langle q_1, \varepsilon \rangle \rightarrow \langle q_2, \alpha \rangle \in \Delta_Q \\ & \qquad \qquad \qquad \langle p_1, \alpha \rangle \rightarrow \langle p_2, \varepsilon \rangle \in \Delta_P \} \\ & \cup \{ \langle (q, p_1), \varepsilon \rangle \rightarrow \langle (q, p_2), a \rangle \mid \langle p_1, \varepsilon \rangle \rightarrow \langle p_2, a \rangle \in \Delta_P \} \end{aligned}$$

читаем с stdin
перенаправление инфы
добавляем в stdout

Лемма: $\langle (q_1, p_1), u, \varepsilon \rangle \vdash_{M_{comp}} \langle (q_2, p_2), \varepsilon, v \rangle \iff \exists w \in \Gamma^* : \langle q_1, u, \varepsilon \rangle \vdash_{M_Q} \langle q_2, \varepsilon, w \rangle$ и $\langle p_1, w, \varepsilon \rangle \vdash_{M_P} \langle p_2, \varepsilon, v \rangle$

\Rightarrow : индукция по длине вывода в M_{comp} . В переходе делаем разбор случаев: (a, ε) , $(\varepsilon, \varepsilon)$, (ε, a)

▲ База: 0 шагов

$\langle (q_1, p_1), u, \varepsilon \rangle \vdash_0 \langle (q_2, p_2), \varepsilon, v \rangle$.

Значит, $q_1 = q_2, p_1 = p_2, u = \varepsilon, v = \varepsilon$

Переход:

Мы имеем следующее: $\langle (q_1, p_1), u, \varepsilon \rangle \vdash \langle (q_3, p_3), u', v' \rangle \vdash_1 \langle (q_2, p_2), \varepsilon, v \rangle$

Далее у нас есть 3 случая в зависимости от того, какой был последний переход (они соответствуют трем множествам из объединения для Δ):

1. Можем сделать несколько выводов:

- (a) $u' = a$
- (b) $v' = v$
- (c) $p_3 = p_2$
- (d) $\langle q_3, a \rangle \rightarrow \langle q_2, \varepsilon \rangle \in \Delta_p$ (исходное Δ)

Поэтому $\langle (q_1, p_1), u''a, \varepsilon \rangle \vdash \langle (q_3, p_2), a, v \rangle \Rightarrow \langle (q_1, p_1), u'', \varepsilon \rangle \vdash \langle (q_3, p_2), \varepsilon, v \rangle$.

Значит, по предположению индукции, $\exists w : \langle q_1, u'', \varepsilon \rangle \vdash \langle q_3, \varepsilon, w \rangle$ и $\langle p_1, w, \varepsilon \rangle \vdash \langle p_2, \varepsilon, v \rangle$. (Получили одну из нужных выводимостей).

А еще $\langle q_1, u''a, \varepsilon \rangle \vdash \langle q_3, a, w \rangle \vdash \langle q_2, \varepsilon, w \rangle$.

2. Можем сделать несколько выводов:

$$(a) \ u' = \varepsilon$$

$$(b) \ v' = v$$

$$(c) \ \exists \alpha \in \Gamma :$$

$$\langle q_3, \varepsilon \rangle \rightarrow \langle q_2, \alpha \rangle \text{ и } \langle p_3, \alpha \rangle \rightarrow \langle p_2, \varepsilon \rangle$$

Из $\langle (q_1, p_1), u, \varepsilon \rangle \vdash \langle (q_3, p_3), \varepsilon, v \rangle$ по предположению индукции следует, что

$$\exists w \in \Gamma^* :$$

$$\langle q_1, u, \varepsilon \rangle \vdash \langle q_3, \varepsilon, w \rangle - (1)$$

$$\langle p_1, w, \varepsilon \rangle \vdash \langle p_3, \varepsilon, v \rangle - (2)$$

Применим к (1) результаты вывода номер 3 и получим: $\langle q_3, \varepsilon, w \rangle \vdash \langle q_2, \varepsilon, w\alpha \rangle$

А, воспользовавшись уже второй выводимостью из вывода номер 3 получим:

$$\langle p_1, w\alpha, \varepsilon \rangle \vdash \langle p_3, \alpha, v \rangle \vdash \langle p_2, \varepsilon, v \rangle$$

Из существования $w\alpha$ – переход выполнен.

3. Можем сделать несколько выводов:

$$(a) \ q_3 = q_2$$

$$(b) \ v = v'a$$

$$(c) \ u' = \varepsilon$$

$$(d) \ \langle p_3, \varepsilon \rangle \rightarrow \langle p_2, a \rangle \in \Delta_p$$

Из $\langle (q_1, p_1), u, \varepsilon \rangle \vdash \langle (q_2, p_3), \varepsilon, v' \rangle$ по предположению индукции следует, что

$$\exists w \in \Gamma^* :$$

$$\langle q_1, u, \varepsilon \rangle \vdash \langle q_2, \varepsilon, w \rangle - (1)$$

$$\langle p_1, w, \varepsilon \rangle \vdash \langle p_3, \varepsilon, v' \rangle - (2)$$

Из (2) и вывода номер 4: $\langle p_3, \varepsilon, v' \rangle \vdash \langle p_2, \varepsilon, v'a \rangle$ ($v'a = v$, поэтому переход готов)

■

\Leftarrow : индукция по сумме длин выводов в M_Q и M_P . В переходе расписываем чтение буквы a и написание α

$$\blacktriangle \text{ База: } k = 0, m = 0$$

Тогда $q_1 = q_2, u = \varepsilon, w = \varepsilon, v = \varepsilon, p_1 = p_2$. Тогда утверждение, очевидно, верно.

Переход: И снова случаи

1. Чтение буквы a .

$$\exists w : \langle q_1, u, \varepsilon \rangle \vdash \langle q_3, a, w \rangle \vdash \langle q_2, \varepsilon, w \rangle - (1)$$

Далее получим 2 выводимости:

$$\langle p_1, w, \varepsilon \rangle \vdash \langle p_2, \varepsilon, v \rangle \text{ и } \langle q_1, u', \varepsilon \rangle \vdash \langle q_3, \varepsilon, w \rangle.$$

Применим к ним предположение индукции:

$$\langle (q_1, p_1), u', \varepsilon \rangle \vdash \langle (q_3, p_2), \varepsilon, v \rangle$$

Тогда (из свойств нашего перехода и (1)):

$$\langle (q_1, p_1), u' a, \varepsilon \rangle \vdash \langle (q_3, p_2), a, v \rangle \vdash \langle (q_2, p_2), \varepsilon, v \rangle.$$

Переход доказан.

2. Пишем α и читаем α Мы имеем следующее $\exists w = a' \alpha : \langle q_1, u, \varepsilon \rangle \vdash \langle q_3, \varepsilon, w' \rangle \vdash \langle q_2, \varepsilon, w' \alpha \rangle -$
(1)

$$\langle p_1, w' \alpha, \varepsilon \rangle \vdash \langle p_2, \varepsilon, v \rangle - (2)$$

Из (1) получим $(q_3, \varepsilon) \rightarrow (q_2, \alpha)$, а из (2) получим $(p_3, \alpha) \rightarrow (p_2, \varepsilon)$.

Тогда из них можно собрать мощное правило $\langle (q_3, p_3), \varepsilon \rangle \rightarrow \langle (q_2, p_2), \varepsilon \rangle$

Применив предположение индукции и это правило получим

$$\langle (q_1, p_1), u, \varepsilon \rangle \vdash \langle (q_3, p_3), \varepsilon, v \rangle \vdash \langle ((q_2, p_2)), \varepsilon, v \rangle$$

3. Пишем букву a . Аналогично случаю 2.

■

Покажем, почему *Lemma* \implies *Theorem*:

$$(u, v) \in \psi \iff \exists (q, p) : q \in F_Q, p \in F_P \text{ т.ч. } \langle (q_0, p_0), u, \varepsilon \rangle \vdash \langle (q, p), \varepsilon, v \rangle \xLeftrightarrow{\text{lemma}}$$

$$\exists w : \langle q_0, u, \varepsilon \rangle \vdash_{M_Q} \langle q, \varepsilon, w \rangle \text{ и } \langle p_0, w, \varepsilon \rangle \vdash_{M_P} \langle p, \varepsilon, v \rangle \iff$$

$$\exists w : (u, w) \in \psi_1 \text{ и } (w, v) \in \psi_2 \iff (u, v) \in \psi_2 \circ \psi_1$$

■

31. Замкнутость класса автоматных языков относительно конечных преобразований.

Теорема.

Если L – автоматный язык, ψ – конечное преобразование, то $\psi(L)$ – автоматный язык.

Доказательство

Так как ψ – конечное преобразование, то по теореме Нива существуют такие η, R, φ , что $\psi = \eta \circ id|_R \circ \varphi^{-1}$, где η, φ – неудлиняющие гомоморфизмы, R – регулярный (автоматный) язык.

Введём обозначения:

- 1) $\varphi^{-1}(L) = L_1$
- 2) $id|_R(L_1) = L_2$
- 3) $\eta(L_2) = L_3$.

Тогда нужно доказать, что L_1, L_2, L_3 – автоматные языки.

- 1) φ – неудлиняющий гомоморфизм, а значит $\forall x \in \Sigma \varphi(x) = \varepsilon$ или $\varphi(x) = a \in \Sigma$

Обозначим

$$\Gamma_\varepsilon = \{u \in \Sigma \mid \varphi(u) = \varepsilon\}$$

$$\Gamma_a = \{u \in \Sigma \mid \varphi(u) = a\}$$

Так как L – автоматный язык, то для него существует задающий его автомат, на рёбрах которого написана ровно одна буква. Преобразуем этот автомат так, чтобы он распознавал L_1 :

У каждой вершины сделаем петли по Γ_ε

Если был переход по a , то заменим его переходами по Γ_a .

- 2) $L_2 = L_1 \cap R$. Воспользуемся тем, что пересечение автоматных языков – автоматный язык.
- 3) Построим автомат для L_2 и заменим переходы по a на $\eta(a)$.

32. Замкнутость класса контекстно-свободных языков относительно конечных преобразований.

Теорема.

Если L – контекстно-свободный язык, ψ – конечное преобразование, то $\psi(L)$ – контекстно-свободный язык.

Доказательство

Так как ψ – конечное преобразование, то по теореме Нива существуют такие η, R, φ , что $\psi = \eta \circ id|_R \circ \varphi^{-1}$, где η, φ – неудлиняющие гомоморфизмы, R – регулярный (автоматный) язык.

Тогда достаточно доказать 3 утверждения:

- 1) Если φ – неудлиняющий гомоморфизм и L – КС-язык, то $\varphi^{-1}(L)$ – КС-язык.
- 2) Если R – регулярный язык и L – КС-язык, то $id|_R(L) = L \cap R$ – КС-язык.
- 3) Если φ – неудлиняющий гомоморфизм и L – КС-язык, то $\varphi(L)$ – КС-язык.

1) Введем обозначения:

$$\Gamma_\varepsilon = \{u \in \Gamma \mid \varphi(u) = \varepsilon\}$$

$$\Gamma_a = \{u \in \Gamma \mid \varphi(u) = a\}$$

$$\text{Тогда } \varphi^{-1}(\varepsilon) = \Gamma_\varepsilon^*, \text{ а } \varphi^{-1}(a) = \Gamma_\varepsilon^* \Gamma_a \Gamma_\varepsilon^*$$

Заведём нетерминалы S_a :

$$S_a \vdash \varphi^{-1}(a) = \Gamma_\varepsilon^* \Gamma_a \Gamma_\varepsilon^*$$

Так как $\Gamma_\varepsilon^* \Gamma_a \Gamma_\varepsilon^*$ – регулярный, то построим $G_a = \langle \dots, S_a \rangle$, распознающий этот язык.

L – КС-язык, следовательно, существует КС-грамматика в нормальной форме Хомского $G = \langle N, \Sigma, P, S \rangle : L(G) = L$, то есть в ней есть только правила вида $S \rightarrow \varepsilon, A \rightarrow BC, A \rightarrow a$.

Заменим правила в ней следующим образом:

$S \rightarrow \varepsilon$ заменим на $S \rightarrow S_\varepsilon$, при этом добавим правила $S_\varepsilon \rightarrow xS_\varepsilon \forall x \in \Gamma_\varepsilon$ и $S_\varepsilon \rightarrow \varepsilon$.

$S \rightarrow AB$ заменим на $S \rightarrow S_\varepsilon AS_\varepsilon BS_\varepsilon$.

$A \rightarrow a$ заменим на $A \rightarrow S_a$

2) Если L – КС-язык, R – регулярный язык, то $L \cap R$ – КС-язык.

Пусть R – регулярный язык, заданный своим ДКА $\langle \Sigma, Q_1, s_1, T_1, \delta_1 \rangle$, и L – КС-язык, заданный своим МП-автоматом: $\langle \Sigma, \Gamma, Q_2, s_2, T_2, z_0, \delta_2 \rangle$. Тогда прямым произведением назовем следующий автомат:

- $Q = \{\langle q_1, q_2 \rangle \mid q_1 \in Q_1, q_2 \in Q_2\}$. Иначе говоря, состояние в новом автомате – пара из состояния первого автомата и состояния второго автомата.
- $s = \langle s_1, s_2 \rangle$
- Стековый алфавит Γ остается неизменным.

- $T = \{\langle t_1, t_2 \rangle \mid t_1 \in T_1, t_2 \in T_2\}$. Допускающие состояния нового автомата – пары состояний, где оба состояния были допускающими в своем автомате.
- $\delta(\langle q_1, q_2 \rangle, c, d) = \langle \delta_1(q_1, c), \delta_2(q_2, c, d) \rangle$. При этом на стек кладется то, что положил бы изначальный МП-автомат при совершении перехода из состояния q_2 , видя на ленте символ c и символ d на вершине стека.

Этот автомат использует в качестве состояний пары из двух состояний каждого автомата, а за операции со стеком отвечает только МП-автомат. Слово допускается этим автоматом \Leftrightarrow слово допускается и ДКА, и МП-автоматом, то есть язык данного автомата совпадает с $R \cap L$.

3) L – КС-язык, следовательно, существует КС-грамматика в нормальной форме Хомского $G = \langle N, \Sigma, P, S \rangle : L(G) = L$, то есть в ней есть только правила вида $S \rightarrow \varepsilon, A \rightarrow BC, A \rightarrow a$. Для того, чтобы эта грамматика задавала язык $\varphi(L)$ достаточно заменить правила вида $A \rightarrow a$ на $A \rightarrow \varphi(a)$ (остальные правила оставить без изменений).

$$S \vdash_G w \Leftrightarrow S \vdash_{G'} \varphi(w)$$

Идея доказательства: по индукции можно доказать, что

$$A \vdash_G w \Leftrightarrow A \vdash_{G'} \varphi(w).$$

33. Лемма о разрастании для конечных преобразований. Примеры соответствий, не задаваемых конечными преобразованиями.

Лемма.

Пусть ψ – конечное преобразование. Тогда:

$$\exists p : \forall (u, v) \in \psi : |u| + |v| \geq p \quad \exists x_1, y_1, z_1 \in \Sigma^*, x_2, y_2, z_2 \in \Gamma^* : u = x_1 y_1 z_1, v = x_2 y_2 z_2 :$$

$$|y_1| + |y_2| > 0, |x_1 y_1| + |x_2 y_2| \leq p : \forall k \in \mathbb{N} (x_1 y_1^k z_1, x_2 y_2^k z_2) \in \psi$$

Доказательство

Пусть M – конечный преобразователь с однобуквенными переходами, задающий конечное преобразование ψ .

Положим $p = |Q|$. Условие $|u| + |v| \geq p$ означает, что мы посетили $\geq p + 1$ состояние, а значит $\exists q \in Q$, которое посетили дважды (если их несколько, рассмотрим самую первую).

Пусть $\langle q_0, x_1 y_1 z_1, \varepsilon \rangle \vdash \langle q, y_1 z_1, x_2 \rangle, \langle q, y_1 z_1, x_2 \rangle \vdash \langle q, z_1, x_2 y_2 \rangle, \langle q, z_1, x_2 y_2 \rangle \vdash \langle q_f, \varepsilon, x_2 y_2 z_2 \rangle$.

Тогда $|y_1| + |y_2| > 0$ (так как M – конечный преобразователь с однобуквенными переходами) и $|x_1 y_1| + |x_2 y_2| \leq p$ (иначе q – не первое пересечение по состояниям, так как нашёлся бы другой цикл).

Тогда из-за условия $\langle q, y_1 z_1, x_2 \rangle \vdash \langle q, z_1, x_2 y_2 \rangle$ можно бесконечно "накачивать" y_1 и y_2 . Более формально, $\forall k \in \mathbb{N} (x_1 y_1^k z_1, x_2 y_2^k z_2) \in \psi$.

Пример соответствия, не задаваемого конечным преобразованием

$$\psi : w \rightarrow w^R$$

Докажем, что это преобразование нельзя задать конечным преобразованием.

Зафиксируем произвольное p . Тогда $(a^p b^p, b^p a^p) \in \psi$.

$$a^p b^p = x_1 y_1 z_1, b^p a^p = x_2 y_2 z_2$$

$$|x_1 y_1| + |x_2 y_2| \leq p \Rightarrow x_1 y_1 = a^l, x_2 y_2 = b^m$$

Пусть $y_1 = a^t, t > 0$. Тогда $x_1 y_1^2 z_1 = a^{p+t} b^p$.

$$|x_2 y_2^2 z_2|_a = p < p + t, \text{ то есть } (x_1 y_1^2 z_1, x_2 y_2^2 z_2) \notin \psi.$$